



Pontificia Universidad
JAVERIANA
Cali

[VERIFICADA MINEDUCACIÓN No. 12226 de 2016]

PONTIFICIA UNIVERSIDAD JAVERIANA CALI
FACULTAD DE INGENIERÍA Y CIENCIAS.
MAESTRÍA EN CIENCIA DE DATOS

Metodología Basada en Métodos de Ciencia de Datos para Pronosticar la Frecuencia y la Duración de Interrupciones Eléctricas (Variables Proxy Asociadas a SAIDI y SAIFI) en Redes de Distribución de una Empresa de Energía Eléctrica en el Norte de Santander

Edwin Henao Ochoa

Cindy Lugo Rozo

Edwin Silva Salas

DIRECTOR

Sandra Milena Ramírez Buelvas

Pontificia Universidad Javeriana



A nuestras familias y amigos
Edwin Henao Ochoa
Cindy Lugo Roza
Edwin Silva Salas

Índice general

Resumen	VII
Introducción	VIII
1 Definición del problema	1
1.1 Planteamiento del problema	1
1.2 Formulación del problema	3
2 Objetivos del proyecto	5
2.1 Objetivo general	5
2.2 Objetivos específicos	5
3 Marco de referencia	6
3.1 Marco teórico	6
3.1.1 Contexto del estudio	6
3.1.2 Métodos y modelos	10
3.2 Antecedentes	13
3.2.1 Revisión de literatura	13
4 Datos	16
Tiempo o periodo de estudio.	16
Unidad muestral.	16
4.1 Construcción del dataset	16
4.1.1 Lógica estructural	16
4.1.2 Definición de variables de evento	17
4.1.3 Estructura del dataset consolidado	17
Número de observaciones.	17
Origen de la información.	18
Lugar donde se registra la información.	18
5 Metodología	19
5.1 Etapa 1 – Extracción de datos	19
Fuentes de informacion	20
5.1.1 Sistemas y fuentes consultadas	20
5.1.2 Extracción base y depuración de eventos de interrupción (BRAE)	20

5.1.3	Extracción de afectación por evento	22
5.1.4	Extracción del elemento causante histórico	23
5.1.5	Extracción del elemento causante actual	24
5.1.6	Extracción de inventario GIS	26
5.1.7	Extracción de variables meteorológicas	27
5.1.8	Resumen metodológico de extracción e integración de bases de datos	28
5.2	Etapa 2 - Integración y depuración de datos	30
5.2.1	Lógica de integración entre sistemas	30
5.2.2	Diagrama de flujo de la secuencia de integración	33
5.2.3	Descripción de la tabla base consolidada	33
5.2.4	Descripción de las variables	35
	Tabla 5.9 (severidad y clima inicial).	35
	Tabla 5.10 (clima complementario).	36
	Tabla 5.11 (variables de continuidad).	36
5.2.5	Agrupación de data consolidada por semana y cuadrante	37
	Definición del grano analítico (cuadrante $\times$ semana) . . .	37
	Procedimiento de agregación	38
5.2.6	Descripción de la tabla base semanal cuadrante	39
5.2.7	Evidencia de calidad y confiabilidad de las fuentes	39
5.3	Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA) . . .	42
5.3.1	Identificación de datos faltantes	43
	Tabla agrupada cuadrante $\times$ semana.	45
5.3.2	Identificación de valores extremos en variables cuantitativas	45
	Panel consolidado activo $\times$ día.	46
	Tabla agrupada cuadrante $\times$ semana.	48
5.3.3	Cálculo de estadísticos descriptivos	52
	Variables climáticas semanales.	52
	Variables de severidad y continuidad.	55
5.3.4	Análisis de la distribución de variables	58
	Variables climáticas.	58
	Variables de severidad y continuidad.	58
5.3.5	Análisis temporal de eventos	59
	Evolución de la serie semanal.	60
	Diagnóstico de cobertura del emparejamiento evento–elemento.	61
	Estacionalidad intra-anual.	63
	Autocorrelación temporal.	63
	Evolución de la severidad y extensión territorial. . .	63
	Materialización de D_{mod}	65
5.3.6	Identificación de patrones, tendencias y visualización exploratoria	65
	Patrones temporales.	66

	Patrones espaciales.	66
	Patrones clima–evento.	68
5.3.7	Análisis de correlación y asociación	70
	Matriz de asociación global.	70
	Bloque climático: redundancias.	70
	Bloque operativo.	72
	Clima → operativo.	72
	Análisis condicionado.	73
5.3.8	Evaluación inicial de relaciones multivariadas	75
	Multicolinealidad climática (VIF).	75
	PCA exploratorio del bloque climático.	76
	Agrupamiento jerárquico.	76
	Asociación multivariada clima → n_eventos.	76
	Dimensiones del bloque operativo.	78
5.3.9	Segmentación exploratoria	78
	Perfiles por nivel de actividad.	79
	Evolución 2024 vs 2025 por estrato.	79
	Régimen climático semanal.	79
	Clustering multivariado de cuadrantes.	81
5.3.10	Resultados y entregables de la etapa	83
5.4	Etapa 4 – Ingeniería de variables y preparación del modelo	83
5.4.1	Construcción de variables predictoras	84
5.4.2	Construcción de la variable respuesta	84
5.4.3	Análisis de asociación y depuración de variables cuantita- tivas	84
5.4.4	Análisis de asociación y depuración de variables cualitativas	84
5.4.5	Codificación de variables categóricas	84
5.4.6	Estandarización de variables cuantitativas	84
5.4.7	Generación de ventanas temporales	84
5.4.8	Partición de datos en entrenamiento y prueba	84
5.4.9	Construcción de matrices de diseño	84
5.4.10	Reducción de dimensionalidad	84
5.4.11	Segmentación analítica	84
5.4.12	Transformaciones adicionales para modelado	84
5.4.13	Resultados y entregables de la etapa	84
5.5	Etapa 5 – Modelado predictivo y evaluativo	85
5.5.1	Selección de algoritmos	85
5.5.2	Entrenamiento del modelo	85
5.5.3	Validación del modelo	85
5.5.4	Ajuste de hiperparámetros	85
5.5.5	Evaluación de desempeño	85
5.5.6	Comparación de modelos	85
5.5.7	Interpretación de resultados	85

5.5.8	Resultados y entregables de la etapa	85
5.6	Etapa 6 – Cierre metodológico, documentación y reportes	85
5.6.1	Presentación de resultados del modelo	86
5.6.2	Métricas de desempeño	86
5.6.3	Hallazgos principales	86
5.6.4	Interpretación técnica y operativa	86
5.6.5	Generación de reportes	86
5.6.6	Discusión de resultados	86
5.6.7	Limitaciones y trabajos futuros	86
5.6.8	Resultados y entregables de la etapa	86
6	Resultados	87
6.1	Resultados de la estimación del modelo	87
7	Discusión y trabajo futuro	88
7.1	Discusión	88
7.2	Trabajos futuros	88
8	Conclusiones	89
8.1	Conclusión asociada al objetivo general	89
8.2	Conclusión asociada al objetivo específico 1	89
8.3	Conclusión asociada al objetivo específico 2	89
8.4	Conclusión asociada al objetivo específico 3	89
A	Appendix	95
A.1	Parte 1	95
A.2	Parte 2	95

Resumen

En este estudio se desarrolla una metodología basada en el estándar CRISP-DM para la predicción de dos indicadores fundamentales de la calidad del servicio eléctrico: SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema), aplicados a las redes de distribución de una empresa ubicada en el departamento de Norte de Santander. Actualmente, la operación del sistema se apoya en múltiples plataformas heterogéneas, tales como SCADA, OMS, GIS, CIS e información climática proveniente del IDEAM, cuyos registros operativos no siempre son fácilmente interpretables ni consistentes entre sí, lo que puede generar conflictos relevantes frente al cumplimiento de la regulación vigente. En este contexto, el objetivo del estudio consiste en integrar y armonizar estas fuentes de información en un sistema analítico unificado que permita identificar cuáles variables técnicas, operativas y climáticas influyen de manera significativa en el comportamiento de los indicadores, con el fin de evaluar distintos modelos predictivos a nivel de circuito. La metodología propuesta se estructura en cuatro etapas principales: (i) integración y estandarización de las fuentes de datos, (ii) desarrollo de un análisis exploratorio detallado, (iii) selección de variables relevantes y (iv) comparación de métodos estadísticos y de aprendizaje automático, incluyendo enfoques supervisados, no supervisados e híbridos, definidos a partir del conocimiento obtenido en el análisis exploratorio. El desempeño de los modelos se evalúa mediante métricas de error ampliamente utilizadas en tareas de pronóstico, tales como MAE, RMSE y MAPE. Como resultado del proceso metodológico, se generarán códigos reproducibles implementados en cuadernos computacionales y contenedores, un documento con el análisis exploratorio integral, un informe comparativo de modelos y un reporte final que identifique las variables con mayor capacidad explicativa sobre SAIDI y SAIFI. En términos aplicados, esta estrategia busca reducir las interrupciones no programadas mediante la identificación temprana de circuitos críticos, optimizar la asignación de recursos hacia mantenimiento preventivo basado en evidencia empírica y fortalecer el cumplimiento de los lineamientos regulatorios establecidos por la CREG y la SSPD, contribuyendo así a mejorar la confiabilidad del servicio eléctrico para más de 600,000 usuarios en la región.

Introducción

Sin duda, la energía eléctrica es vital para el progreso de cada región, tanto social, económica como industrialmente. En Colombia, el acceso a este servicio está estrictamente regulado en términos de provisión, con el objetivo de asegurar que todos los usuarios cuenten con un suministro de energía constante, seguro y de alta calidad para vivir y trabajar [1]. Los operadores de red tienen de manera continua la responsabilidad de garantizar que la entrega de energía sea confiable para hogares, instituciones y negocios, evitando fallas en la prestación del servicio en cualquier tipo de edificación.

No obstante, esta tarea no es sencilla. La operación de los sistemas de distribución de energía se ve afectada por múltiples factores técnicos, ambientales y operativos, así como por la duración y frecuencia de las interrupciones del servicio. En este contexto, la Comisión de Regulación de Energía y Gas (CREG) adoptó los indicadores SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) como los criterios oficiales para evaluar la calidad del servicio en las redes de distribución, mediante la Resolución CREG 015 de 2018 [1]. Estos indicadores permiten evaluar el desempeño operativo y facilitan la implementación de esquemas de compensación y control por parte de la Superintendencia de Servicios Públicos Domiciliarios (SSPD) [2].

Sin embargo, la gestión efectiva de estos indicadores ha resultado compleja, dada la heterogeneidad de los eventos que originan las interrupciones y la limitada conectividad de la información almacenada en sistemas dispares como SCADA, OMS, GIS, CIS y bases de datos externas.¹ Debido a que los registros operativos, climáticos y de mantenimiento se encuentran dispersos y fragmentados en múltiples plataformas, construir modelos analíticos capaces de pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas en distintas áreas o circuitos representa un desafío significativo.

Esta brecha limita la capacidad de las empresas para tomar decisiones oportu-

¹SCADA (*Supervisory Control and Data Acquisition*): sistema de supervisión y adquisición de datos de la operación de la red. OMS (*Outage Management System*): sistema de gestión de interrupciones. GIS (*Geographic Information System*): sistema de información geográfica de activos. CIS (*Customer Information System*): sistema de información de clientes.

nas, priorizar inversiones, mejorar la planificación del mantenimiento y responder adecuadamente a los requerimientos regulatorios. En consecuencia, resulta fundamental desarrollar herramientas apoyadas en ciencia de datos que permitan consolidar información histórica, identificar patrones relevantes y pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas.

Este trabajo presenta técnicas para la recopilación de datos provenientes de plataformas operativas internas y fuentes externas, así como el análisis de modelos estadísticos y de aprendizaje automático orientados al **pronóstico de la frecuencia y el tiempo de duración de interrupciones eléctricas** en una empresa de distribución de energía que opera en el departamento de Norte de Santander, en el marco de los indicadores regulatorios SAIDI y SAIFI. Al adoptar esta estrategia, se busca anticipar cuándo y con qué intensidad operativa pueden ocurrir las interrupciones, e identificar las influencias técnicas, operativas y climáticas más relevantes en la continuidad del servicio. Este desarrollo constituye una contribución significativa para fortalecer la toma de decisiones basada en evidencia, optimizar los planes de mantenimiento, apoyar el cumplimiento regulatorio y ofrecer un caso académico aplicado sobre el uso de técnicas analíticas en el sector eléctrico regulado, beneficiando a más de 600,000 usuarios.

El documento se organiza de la siguiente manera. En la Sección 1 se presenta el planteamiento y la formulación del problema de continuidad del servicio. En la Sección 2 se exponen el objetivo general y los objetivos específicos, alineados con las preguntas de investigación. En la Sección 3 se desarrolla el marco teórico (definiciones regulatorias de SAIDI y SAIFI, exclusiones y factores asociados) y los antecedentes sobre modelación de interrupciones e indicadores de confiabilidad. En la Sección 4 se describe la fuente y la estructura de los datos empleados. En la Sección 5 se detallan las etapas metodológicas —desde la extracción e integración hasta el EDA, la ingeniería de variables y el modelamiento— orientadas al pronóstico de la frecuencia y el tiempo de duración de interrupciones eléctricas. Posteriormente, en la Sección 6 se presentan los resultados por etapa; en la Sección 7 se discute el alcance, los aportes y las limitaciones frente a cada objetivo; y en la Sección 8 se consolidan las conclusiones del trabajo.

Definición del problema

1.1. Planteamiento del problema

Los indicadores de continuidad del servicio SAIDI (Índice de Duración Promedio de Interrupción del Sistema) y SAIFI (Índice de Frecuencia Promedio de Interrupción del Sistema) en la empresa de distribución objeto de estudio presentan dificultades estructurales para su mejora sostenida. Si bien existen técnicas estadísticas y de aprendizaje automático ampliamente documentadas para el análisis de interrupciones en sistemas eléctricos, la principal limitación no radica en la ausencia de metodologías analíticas, sino en la calidad, estructura e interpretación de los datos disponibles, lo que dificulta el entrenamiento de modelos predictivos que sean simultáneamente confiables y explicativos [1], [2], [3]. En particular, resulta complejo detectar, cuantificar y explicar no solo las causas de las interrupciones, sino también su duración y los tiempos de restauración del servicio.

Los principales obstáculos identificados son los siguientes:

- **Fragmentación de las fuentes de información:** La operación del sistema requiere el uso de múltiples registros provenientes de plataformas heterogéneas como SCADA, OMS, GIS, CIS, bases de mantenimiento y fuentes meteorológicas externas. Estos datos se encuentran en distintos formatos, con estructuras disímiles y, en algunos casos, con ausencia de metadatos completos, lo que dificulta su integración sin pérdida de trazabilidad [4], [5].
- **Problemas de sincronización temporal:** Los sistemas operativos no presentan una alineación temporal uniforme. Mientras algunos registran información en intervalos horarios, otros lo hacen en escalas de minutos o presentan series discontinuas. Esta falta de sincronización genera inconsistencias que afectan la estimación precisa de la duración de las interrupciones y de los tiempos de reposición del servicio [4], [6].
- **Eventos extremos y ruido en los datos:** Los registros contienen alta variabilidad, errores de captura, información incompleta y eventos atípicos,

como fenómenos climáticos extremos o fallas excepcionales, que suelen ser excluidos del análisis. Esta situación dificulta la identificación de patrones robustos tanto a nivel agregado como local [1], [7].

- **Pérdida de detalle por agregación:** El uso de indicadores promediados en escalas anuales o geográficas amplias oculta el comportamiento específico de circuitos o zonas particulares, lo que limita la identificación de causas operativamente accionables [2], [6].
- **Ausencia de estándares de datos:** La falta de catálogos de datos, definiciones homogéneas y métricas de integridad impide evaluar de manera sistemática si las fuentes disponibles son adecuadas para la construcción de modelos predictivos confiables [4], [5].
- **Restricciones regulatorias:** Los organismos de control exigen que los resultados sean trazables y explicables. En consecuencia, no es suficiente emplear modelos con alto desempeño predictivo; estos deben ser interpretables y compatibles con los requerimientos de reporte regulatorio, lo que condiciona el tipo de metodologías que pueden adoptarse [2], [3].

Estos obstáculos reducen la capacidad de la organización para explicar la variación de los indicadores SAIDI y SAIFI, priorizar actividades operativas y cumplir con los requerimientos regulatorios mediante herramientas predictivas [3], [4], [7]. En términos cuantitativos, el SAIDI promedio de la empresa es de 22.430 horas por año, valor que se ubica un 4.640 % por debajo de la meta establecida por la CREG (23.522 horas por año). Para el indicador SAIFI, el promedio anual es de 6.500 eventos, significativamente inferior al objetivo regulatorio de 9 eventos por año, lo que representa una reducción del 27.780 % [8]. Estos resultados sugieren que la empresa se encuentra dentro de los límites regulatorios; sin embargo, la gestión de dichos indicadores enfrenta importantes desafíos operativos e informativos.

Las compensaciones anuales asociadas a calidad del servicio ascienden aproximadamente a \$5 mil millones de pesos, y el análisis de datos históricos de cinco años evidencia que cerca del 2 % de los registros presenta información faltante o inconsistente, como tiempos de evento no registrados, campos incompletos o desajustes temporales entre sistemas. Si bien la Circular 063 de 2019 de la SSPD establece criterios técnicos para la exclusión válida de eventos asociados a factores externos, como fuerza mayor o fallas del Sistema Nacional de Transmisión, la presencia de problemas de calidad de datos limita la capacidad de construir modelos predictivos sólidos, diagnosticar con precisión las causas de las interrupciones y priorizar acciones operativas basadas en evidencia [1], [2], [3], [9].

Este problema no es exclusivo de la empresa analizada. En el sector eléctrico colombiano, la calidad del servicio constituye un desafío estructural. De acuerdo con el Informe de Calidad del Servicio de Energía Eléctrica de la SSPD 2023, el SAIDI promedio nacional fue de 16.83 horas por usuario, con valores que oscilaron entre 4.500 horas y más de 50 horas dependiendo del operador y de la región geográfica [10]. Esta dispersión refleja diferencias significativas en infraestructura, gestión operativa y exposición a condiciones climáticas extremas. Durante 2023, el 68 % de las interrupciones estuvo asociado a eventos externos, como contacto con vegetación, animales o terceros, mientras que el 24 % se atribuyó a fallas técnicas en equipos de red, evidenciando la naturaleza multicausal del problema [2].

El impacto regulatorio es considerable: en 2023, las compensaciones totales por incumplimiento de metas de calidad alcanzaron aproximadamente 487,000 millones a nivel nacional, siendo los indicadores de continuidad responsables del 73 % de este valor [2]. Para operadores de red ubicados en zonas con alta exposición climática, como Norte de Santander, la problemática se intensifica. Según datos de la SSPD consolidados por la UPME, los eventos meteorológicos extremos incrementaron en un 35 % las interrupciones no programadas respecto al periodo 2019–2021 [2]. En este contexto, la dispersión de información en sistemas heterogéneos dificulta la identificación de patrones causales, la priorización del mantenimiento preventivo y la detección temprana de circuitos críticos, limitando la capacidad de las empresas distribuidoras para anticipar deterioros en la continuidad del servicio y cumplir de manera consistente con los objetivos regulatorios establecidos por la CREG.

1.2. Formulación del problema

¿Cómo desarrollar una metodología basada en métodos de ciencia de datos para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de zonas en redes de distribución de una empresa de energía eléctrica, ubicada en Norte de Santander, identificando los factores que más influyen en su comportamiento.?

A partir de la formulación anterior, se derivan las siguientes preguntas de sistematización:

1. ¿Cómo consolidar un repositorio analítico unificado y trazable que integre SCADA, OMS, GIS, CIS, registros de mantenimiento y datos climáticos, acompañado de un catálogo de datos y métricas de calidad que permitan para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas?

2. ¿Qué patrones temporales, espaciales, estacionales o comportamientos atípicos caracterizan la variabilidad de SAIDI y SAIFI a nivel de circuito, y de qué manera estos patrones influyen en la comprensión del fenómeno de continuidad del servicio eléctrico y en la identificación de los factores que explican sus fluctuaciones?
3. ¿Qué modelos tienen mejor desempeño para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de circuito o zona?
4. ¿Cómo construir artefactos reproducibles (notebooks, contenedores, documentación) y reportes técnicos alineados con los entregables del proyecto que faciliten la interpretación operativa y el uso de resultados en priorización de mantenimiento y reportes regulatorios?

Objetivos del proyecto

2.1. Objetivo general

Desarrollar una metodología basada en métodos de ciencia de datos para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas a nivel de zonas (SAIDI y SAIFI) en redes de distribución de una empresa de energía eléctrica ubicada en Norte de Santander, identificando los factores que más influyen en su comportamiento.

2.2. Objetivos específicos

1. Consolidar un repositorio analítico unificado y trazable que integre SCADA, OMS, GIS, CIS, registros de mantenimiento y datos climáticos, acompañado de un catálogo de datos y métricas de calidad que permitan para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas.
2. Determinar patrones temporales, espaciales, estacionales o comportamientos atípicos caracterizan la variabilidad de SAIDI y SAIFI a nivel de circuito, y de qué manera estos patrones influyen en la comprensión del fenómeno de continuidad del servicio eléctrico y en la identificación de los factores que explican sus fluctuaciones.
3. Comparar el desempeño de distintos modelos para pronosticar la frecuencia y el tiempo de duración de interrupciones eléctricas (SAIDI y SAIFI) a nivel de circuito o zona.
4. Construir artefactos reproducibles (notebooks, contenedores, documentación) y reportes técnicos alineados con los entregables del proyecto que faciliten la interpretación operativa y el uso de resultados en priorización de mantenimiento y reportes regulatorios.

3.1. Marco teórico

3.1.1. Contexto del estudio

Cuando hablamos de calidad del servicio eléctrico, nos referimos básicamente a entregar energía de forma segura y eficiente, cumpliendo con estándares regulatorios que garanticen continuidad, confiabilidad y estabilidad para todos los tipos de usuarios: residenciales, industriales, comerciales e institucionales. En Colombia, este servicio es esencial y por eso está regulado por la Comisión de Regulación de Energía y Gas (CREG) [3], que ha establecido métricas y estándares específicos para hacer seguimiento a cómo se presta el servicio. Entre estas métricas, dos son particularmente importantes: el SAIDI (*System Average Interruption Duration Index*) y el SAIFI (*System Average Interruption Frequency Index*).

1. **Definición del SAIDI según la Resolución CREG 015 de 2018:** La Resolución CREG 015 de 2018 define el SAIDI como se indica a continuación. En dicha normativa, el **OR** es el **Operador de Red** y el **SDL** es el **Sistema de Distribución Local**.

La calidad media anual del OR se mide a través de los indicadores de duración y frecuencia de los eventos sucedidos en los SDL, que se establecen como se describe a continuación. El indicador SAIDI representa la duración total en horas de los eventos que en promedio percibe cada usuario del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:

$$SAIDI_{j,t} = \frac{\sum_{m=1}^{12} \sum_{i=1}^n D_{i,u,m} \times NU_{i,u,m}}{UT_{j,m} \times 60}, \quad (3.1)$$

donde:

- $SAIDI_{j,t}$: Indicador de duración promedio por usuario, de los

eventos sucedidos en el SDL del OR j , durante el año t , medido en horas al año.

- $D_{i,u,m}$: Duración en minutos del evento i , sucedido durante el mes m , que afectó al activo u perteneciente al SDL del OR j .
- $NU_{i,u,m}$: Número de usuarios que fueron afectados por el evento i sucedido durante el mes m , conectados al activo u .
- $UT_{j,m}$: Número total de usuarios conectados al SDL del OR j en el mes m .
- m : Mes del año t , con enero = 1, ..., diciembre = 12.

2. Definición del SAIFI según la Resolución CREG 015 de 2018: La misma resolución define el SAIFI como:

“El indicador SAIFI representa la cantidad total de los eventos que en promedio perciben todos los usuarios del SDL de un OR, hayan sido o no afectados por un evento, en un período anual. Se establece mediante la siguiente expresión:”

$$SAIFI_{j,t} = \frac{\sum_{m=1}^{12} \sum_{i=1}^n NU_{i,u,m}}{UT_{j,m}}, \quad (3.2)$$

donde:

- $SAIFI_{j,t}$: Indicador de frecuencia promedio por usuario, de los eventos sucedidos en el SDL del OR j , durante el año t , medido en cantidad al año.
- $NU_{i,u,m}$: Número de usuarios que fueron afectados por el evento i sucedido durante el mes m , por encontrarse conectados al activo u .
- $UT_{j,m}$: Número total de usuarios conectados al SDL del OR j en el mes m .
- m : Mes del año t , con enero = 1, ..., diciembre = 12.

Cada OR es responsable del cálculo de los indicadores de calidad del servicio. Para ello, debe utilizar la información reportada conforme a lo establecido en el numeral 5.2.11.3.2 de la Resolución CREG 015 de 2018, así como la información de vinculación definida en el literal a) del numeral 5.2.10 [1]. Esta disposición garantiza que el cálculo de los indicadores se realice con base en registros oficiales, trazables y consistentes con los lineamientos regulatorios vigentes.

3. **Interpretación de los indicadores:** Los indicadores SAIDI y SAIFI miden los *eventos* de interrupción del servicio eléctrico, entendidos como situaciones en las cuales se presenta una pérdida total o parcial del suministro. Dependiendo de su causa y de los criterios regulatorios aplicables, ciertos eventos son incluidos en el cálculo de los indicadores, mientras que otros pueden ser excluidos conforme a la normativa vigente.

El SAIDI expresa el tiempo promedio durante el cual un usuario permanece sin servicio eléctrico en un período determinado. Por su parte, el SAIFI mide la frecuencia promedio con la que un usuario experimenta interrupciones en el mismo período. En conjunto, ambos indicadores permiten evaluar la continuidad y confiabilidad del sistema de distribución.

Desde una perspectiva operativa, valores elevados de SAIDI o SAIFI pueden reflejar deficiencias en el mantenimiento de la red, limitaciones en la infraestructura, obsolescencia tecnológica, fallas en los procedimientos operativos o una alta exposición a factores externos como condiciones climáticas adversas [1], [4]. En consecuencia, estos indicadores no solo describen el desempeño del sistema, sino que también permiten identificar áreas críticas que requieren intervención técnica o inversión en activos.

En el ámbito regulatorio, los OR deben reportar estos indicadores como métricas clave de desempeño y compararlos con las metas establecidas por la CREG. El cumplimiento de dichas metas está asociado a esquemas de remuneración por calidad del servicio, mientras que el incumplimiento puede dar lugar a ajustes tarifarios, obligaciones de reinversión o sanciones económicas [3], [7]. Por tanto, SAIDI y SAIFI no solo constituyen medidas técnicas de continuidad, sino también variables con impacto financiero y regulatorio significativo.

4. **Meta de calidad media del SAIDI:** La Resolución CREG 015 de 2018 establece que la meta de calidad media para el indicador de duración de los eventos en el Sistema de Distribución Local (SDL) de cada OR se determina con base en una expresión específica definida por la regulación. Formalmente, dicha meta se calcula mediante la siguiente formulación:

“La meta para el indicador de frecuencia de los eventos sucedidos en el SDL de cada OR se obtiene con base en la siguiente expresión:”

$$\text{SAIDI_M}_{j,t} = (1 - 0,08) \times \text{SAIDI_M}_{j,t-1}, \quad (3.3)$$

donde:

- $SAIDI_M_{j,t}$: Meta del indicador de duración de eventos, en horas al año, a ser alcanzada por el OR j al finalizar el año t .
- $SAIDI_M_{j,t-1}$: Meta del indicador de duración de eventos, en horas al año, para el año $t - 1$. Para el primer año de aplicación del esquema de calidad de cada OR esta variable será igual al indicador de referencia, $SAIDI_R_j$.

5. **Dimensión social y económica:** Desde una dimensión social y económica, un servicio deficiente ocasiona pérdidas significativas en la productividad empresarial y en los ingresos por remuneración al operador de red, y afecta la operación de instituciones comerciales e industriales. Por ello, mejorar la gestión y la capacidad de predicción de *SAIDI* y *SAIFI* es un objetivo estratégico para los operadores y para la regulación del sector, con impactos directos en usuarios, empresas y entes de control.
6. **Exclusiones de eventos:** Para la realización del cálculo de la calidad del servicio y el seguimiento de estos indicadores se tienen algunas exclusiones que permiten exonerar o excluir eventos de este cálculo. Entre los aspectos de la calidad del servicio de energía eléctrica que no serán observados dentro de este estudio se encuentran las siguientes exclusiones de eventos, tal como lo dicta la regulación CREG 015 del 2018 [3]:
 - Los menores o iguales a 3 minutos.
 - Los debidos a racionamientos programados.
 - Los causados por eventos de activos pertenecientes al Sistema de Transmisión Nacional (STN) y al Sistema de Transmisión Regional (STR).
 - Los eventos requeridos por seguridad ciudadana, solicitados por organismos de socorro o autoridades competentes.
 - Cuando se daña un activo de nivel de tensión 1 de propiedad del usuario.
 - Los debidos a catástrofes naturales.
 - Los debidos a actos de terrorismo.
 - Eventos originados en exigencias de traslados y adecuaciones de la infraestructura eléctrica.
 - Los eventos debidos a trabajos de reposición o modernización en subestaciones.
 - Y otros menos relevantes para este estudio, pero que serán igualmente excluidos.

7. **Factores que afectan los indicadores:** Hay varios factores que deben considerarse, ya que terminan afectando negativamente los indicadores de calidad [1], [4], [6]:

- **El clima:** Las tormentas eléctricas, vientos fuertes y otros fenómenos meteorológicos pueden dañar la infraestructura de distribución y causar interrupciones.
- **Aspectos técnicos e infraestructura:** Si el mantenimiento es deficiente, si los equipos están viejos u obsoletos, o si no hay redundancia en la red, se generan problemas que impactan los indicadores.
- **La gestión operativa:** Cuando falta planificación en el mantenimiento, cuando existen redes y equipos sin hojas de vida documentadas, cuando la respuesta a fallas es lenta o cuando el servicio está saturado, los indicadores se ven afectados. El problema se agrava al tener la información dispersa en múltiples sistemas.
- **Los datos:** Cuando la información está fragmentada en diferentes aplicativos, se dificulta el desarrollo de modelos predictivos que funcionen adecuadamente.

Por lo tanto, analizar en conjunto todas estas situaciones que afectan el indicador de forma negativa o positiva constituye un ejercicio relevante, ya que permitiría fortalecer la confiabilidad de los procesos internos y mejorar la gestión de los indicadores de calidad del servicio público de redes eléctricas de la empresa operadora de red de Norte de Santander.

3.1.2. Métodos y modelos

En este trabajo, la unidad de análisis del modelado es el par **cuadrante** $\times$ **semana** sobre D_{mod} (2024–2025). La **variable respuesta** principal es $Y = n_{\text{eventos}}$ (proxy de frecuencia de interrupciones, asociada conceptualmente a SAIFI) y, de forma complementaria, $Y' = duracion_total$ (proxy de duración acumulada, asociada a SAIDI). El vector de **predictoras climáticas** propuesto es

$$\mathbf{x} = (\text{precip_total_semana}, \text{temp_media_semana}, \text{humedad_media_semana}, \text{viento_medio_semana}), \quad (3.4)$$

eventualmente enriquecido con rezagos temporales de Y y términos de estratificación territorial. A continuación se formalizan los métodos empleados en el EDA y en la preparación/modelado.

1. **Datos faltantes, tipos e imputación:** Sea X_j la j -ésima variable del panel. La proporción de faltantes se define como

$$p_j^{\text{NA}} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}\{X_{ij} = \text{NA}\}.$$

En el panel activo $\times$ día, los NA se concentran en el bloque climático y en ALTITUD; en la tabla agregada cuadrante $\times$ semana (D_{EDA} , D_{mod}) no se observan faltantes. Las reglas de imputación o exclusión se aplican en la Etapa 4 solo donde $p_j^{\text{NA}} > 0$ en el grano de origen.

2. **Análisis de atípicos y extremos:** Para una variable cuantitativa X , se emplean reglas basadas en cuartiles. Con Q_1 y Q_3 los cuartiles e $\text{IQR} = Q_3 - Q_1$, se marcan como extremos candidatos los valores

$$x \notin [Q_1 - k \cdot \text{IQR}, Q_3 + k \cdot \text{IQR}]$$

(p. ej. $k = 1,5$ o $k = 3$), complementados con percentiles altos (P95, P99) sobre `n_eventos`, `duracion_total`, `usuarios_afectados` y `precip_total_semana`. El tratamiento definitivo (retención, winsorización o exclusión) se decide en la Etapa 4.

3. **Transformaciones de variables:** Ante asimetría y ceros, se usa la transformación

$$T(x) = \log(1 + x), \quad x \geq 0,$$

aplicada en particular a `precip_total_semana` y al bloque operativo (`n_eventos`, `duracion_total`, `usuarios_afectados`, `elementos_afectados`) cuando se requieren densidades o PCA más estables.

4. **Series de tiempo y sus características:** Sea E_t el total semanal territorial de eventos. La función de autocorrelación (ACF) en el rezago h es

$$\rho(h) = \frac{\text{Cov}(E_t, E_{t-h})}{\text{Var}(E_t)}.$$

En D_{mod} se observa $\rho(1) \approx 0,80$, lo que motiva incorporar rezagos $E_{t-1}, \dots, E_{t-h}$ (o de `n_eventos` a nivel cuadrante) como predictoras. La PACF complementa la identificación del orden autorregresivo; la estacionalidad mensual se analiza agrupando E_t por mes calendario.

5. **Análisis de correlación:** Por la asimetría y la cero-inflación de las variables

operativas, se emplea el coeficiente de Spearman entre rangos:

$$\rho_S(X, Y) = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)},$$

donde d_i es la diferencia de rangos. El par de mayor interés es (`precip_total_semana`, `n_eventos`), con $\rho_S \approx 0,41$ en D_{mod} .

6. **Datos de entrenamiento y prueba:** La partición es temporal (no aleatoria):

$$\mathcal{D}_{\text{train}} = \{(i, t) : \text{year}(t) = 2024\}, \quad \mathcal{D}_{\text{test}} = \{(i, t) : \text{year}(t) = 2025\},$$

sobre el grano cuadrante i y semana t de D_{mod} , preservando el orden cronológico ante la autocorrelación de la serie.

7. **Validación cruzada:** Cuando se ajusten hiperparámetros en $\mathcal{D}_{\text{train}}$, se prioriza validación *forward-chaining* (bloques temporales sucesivos) en lugar de k -fold aleatorio, para no romper la dependencia temporal de `n_eventos`.
8. **Análisis de componentes principales (PCA):** Dado el bloque climático estandarizado $\mathbf{Z}$, el PCA resuelve

$$\mathbf{Z}^T \mathbf{Z} \mathbf{v}_\ell = \lambda_\ell \mathbf{v}_\ell,$$

y las componentes $\text{PC}_\ell = \mathbf{Z} \mathbf{v}_\ell$ resumen redundancias (temperaturas/vientos). En el EDA, PC1–PC2 explican $\approx 81\%$ de la varianza climática; la precipitación aporta carga relativamente independiente. Sobre el bloque operativo en escala $\log(1 + x)$, PC1 concentra la covarianza común de frecuencia, afectación y duración.

9. **Métodos de agrupación:** Los cuadrantes se segmentan por actividad (cuantiles de $\sum_t \text{n_eventos}$) y, de forma multivariada, por clustering (p. ej. jerárquico o k -means) sobre perfiles de frecuencia, duración y clima, con el fin de estratificar el modelado en zonas de distinto riesgo operativo.
10. **Factor de inflación de la varianza (VIF):** Para cada predictora X_j del bloque climático en un modelo auxiliar lineal `n_eventos` $\sim \mathbf{x}$,

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 proviene de regresar X_j sobre el resto de covariables. Valores altos en `temp_max/temp_min` y `viento_max` motivan el subconjunto reducido $\mathbf{x}$ indicado arriba (VIF aceptables tras la depuración).

11. **Modelo lineal generalizado de Poisson (GLM Poisson):** Como modelo diagnóstico de conteos,

$$Y_i \sim \text{Poisson}(\mu_i), \quad \log \mu_i = \beta_0 + \boldsymbol{\beta}^T \mathbf{x}_i^*,$$

donde $Y_i = \text{n_eventos}$ en la observación cuadrante–semana i y $\mathbf{x}_i^*$ incluye, entre otros, $\log(1 + \text{precip_total_semana})$ y el viento medio estandarizado. Los coeficientes $\hat{\beta}_j$ cuantifican el efecto multiplicativo $e^{\hat{\beta}_j}$ sobre la tasa esperada de interrupciones; este esquema orienta el modelado predictivo de la Etapa 5.

3.2. Antecedentes

3.2.1. Revisión de literatura

Los avances recientes en ciencia de datos, estadística avanzada y aprendizaje automático han impulsado una evolución significativa en los métodos para predecir fallas, gestionar interrupciones y estimar la calidad del servicio en redes de distribución eléctrica.

En primer lugar, varios estudios han explorado la predicción de confiabilidad a partir de modelos híbridos que integran técnicas estadísticas y de inteligencia artificial. Xie et al. [11] desarrollan un modelo integral de pronóstico de confiabilidad que combina redes neuronales artificiales, análisis de relaciones grises y modelos de fallas programadas, demostrando alta aplicabilidad en sistemas en expansión. De manera complementaria, Das et al. [12] proponen un ensamble de redes neuronales profundas que mejora sustancialmente la estimación de interrupciones causadas por viento y descargas eléctricas, superando modelos estadísticos y de comité previos.

En el ámbito de eventos meteorológicos severos, Angalakudati et al. [13] introducen uno de los primeros modelos operativos basados en Machine Learning para la planificación de tormentas, combinando datos climáticos, propiedades físicas de la red e información histórica de daños. En la misma línea, Owerko et al. [14] emplean Graph Neural Networks para procesar mediciones meteorológicas distribuidas en un marco de señales sobre grafos, logrando errores de predicción inferiores al 1.1 % en la región de Nueva York.

El efecto de la vegetación como causa dominante de fallas también ha sido ampliamente estudiado. Cerrai et al. [15] cuantifican el impacto del estándar Enhanced Tree Trimming mediante análisis estadístico y modelos de predicción

de interrupciones, mostrando reducciones entre el 16 % y 48 % en fallas durante tormentas. Por su parte, Eskandarpour y Khodaei [16] introducen un modelo predictivo para componentes de red ante huracanes basado en regresión logística, mientras que Rudin et al. [17] proponen un marco general para extraer conocimiento de datos históricos de la red de Nueva York con el fin de priorizar mantenimiento y estimar la vulnerabilidad de componentes críticos.

Otros aportes relevantes abordan la identificación de causas de fallas. Xu et al. [18] aplican un algoritmo inspirado en sistemas inmunológicos (AIRS) para clasificar causas de interrupción (árboles, animales, rayos), enfrentando el problema de datos desbalanceados. Mientras tanto, Breiman [19] establece los fundamentos teóricos de los Random Forest, técnica ampliamente usada en predicción de fallas debido a su robustez y capacidad de manejar alta dimensionalidad.

La estimación de interrupciones bajo condiciones extremas también ha sido examinada mediante enfoques estadísticos. Han et al. [20] modelan la distribución espacial de fallas durante huracanes en la costa del Golfo utilizando variables físicas medibles. Yang et al. [21] estudian la incertidumbre en modelos de predicción de tormentas y demuestran que el rendimiento de los modelos basados en machine learning depende fuertemente del tamaño y representatividad del conjunto de entrenamiento. A su vez, Kankanala et al. [22] presentan AdaBoost+, un método de ensamble que supera regresión, redes neuronales y mixture of experts para estimar fallas asociadas al viento y los rayos.

Otras investigaciones incorporan análisis multivariable para predecir tipos específicos de interrupciones. Kor et al. [23] evalúan arquitecturas de aprendizaje automático para predecir fallas por viento, nieve e hielo, mientras que Doostan y Chowdhury [24] desarrollan un enfoque probabilístico para fallas asociadas a rayos utilizando aprendizaje no supervisado y técnicas de clasificación balanceada.

Asimismo, Chen y Kezunovic [25] aplican lógica difusa para análisis predictivo de riesgo, y He et al. [26] comparan árboles de regresión no paramétricos (QRF y BART), demostrando ventajas complementarias según la granularidad espacial y las características del evento.

Dentro de los aportes más recientes, Hou et al. [27] desarrollan un enfoque basado en celdas espaciales de 1 km^2 y Random Forest para predecir interrupciones bajo tifones, alcanzando precisiones superiores al 92 %. De forma similar, Li et al. [28] construyen un modelo de predicción de cantidad de usuarios afectados por tifones, aplicando selección de variables para obtener un modelo simplificado sin sacrificar precisión.

Otras líneas introducen enfoques más estructurales o basados en simulación. Zhai et al. [29] proponen un modelo que genera sistemas de distribución sintéti-

cos y estima fallas a nivel de edificio mediante funciones de fragilidad, reduciendo la dependencia en datos privados de operadores. Zhu et al. [30] desarrollan un modelo de tormentas de dos etapas para predecir interrupciones en tiempo real, mientras que Arif y Wang [31] combinan análisis estadístico y redes neuronales profundas para predecir tiempos de reparación.

Wanik et al. [32] demuestran que modelos basados en árboles y ensambles, alimentados con datos atmosféricos generados mediante WRF, pueden predecir con alta resolución espacial la distribución de fallas en Connecticut. Por su parte, Jaech et al. [33] incorporan procesamiento de lenguaje natural para actualizar predicciones de duración de interrupciones a partir de reportes de campo.

Más recientemente, Krstivojević et al. [34] proponen modelos de regresión basados en Machine Learning para predecir indicadores de confiabilidad en redes suecas, mientras que Sorokin [35] emplea técnicas similares para optimizar la planificación del mantenimiento. Además, Lui et al. [36] presentan un método de cálculo rápido para evaluar la confiabilidad bajo condiciones operativas variables, y Avcı [36] integra técnicas híbridas de inteligencia artificial para mejorar la predicción de interrupciones, considerando factores meteorológicos, geográficos y operativos.

Para el desarrollo del modelo de pronóstico de la frecuencia y la duración de interrupciones eléctricas (variables proxy asociadas a SAIDI y SAIFI), se utilizará una base de datos histórica de eventos de falla reportados en el sistema de distribución. La tabla principal consolidada tiene $N = 87,007,074$ observaciones ($A = 47,649$ activos eléctricos únicos $\times T = 1,826$ días), correspondientes al panel **activo $\times$ día** entre el 1 de enero de 2021 y el 31 de diciembre de 2025.

Tiempo o periodo de estudio. El periodo de estudio abarca desde el 1 de enero de 2021 hasta el 31 de diciembre de 2025.

Unidad muestral. La unidad muestral adoptada corresponde a un activo eléctrico por día, lo que define un nivel de granularidad tipo *elemento-día*. Esta elección permite capturar la variabilidad temporal de los eventos e integrar variables de red y climáticas a nivel diario.

4.1. Construcción del dataset

4.1.1. Lógica estructural

La construcción del conjunto de datos sigue la siguiente lógica:

- Se crea un calendario diario para el periodo comprendido entre el 01-01-2021 y el 31-12-2025.
- Se construye el producto cartesiano entre el inventario de activos eléctricos y el calendario diario, garantizando la presencia de todos los activos en cada día del periodo de análisis.
- Sobre esta estructura base se integran:
 - Variables de red.
 - Variables climáticas agregadas a nivel de activo por día.
 - Variables de eventos asociadas a cada activo por día.

4.1.2. Definición de variables de evento

Las variables de eventos se definen así:

- **Duracion (minutos):** duración total del evento de interrupción, expresada en minutos, asignada al día de Fecha_Desconexion (sin prorrateo entre días). En días sin falla, el valor es 0.
- **Frecuencia:** número de interrupciones cuyo inicio (Fecha_Desconexion) ocurre en el día.

4.1.3. Estructura del dataset consolidado

El dataset final incluye las variables agrupadas por bloque temático, como se resume en la Tabla 4.1.

Tabla 4.1: Estructura del dataset consolidado (grano activo × día).

Bloque	Variables
Información del activo	Id_Activo_Electrico
	Tipo_Activo_Electrico
	Latitud
	Longitud
	Altitud
Información geoespacial	Id_Cuadrante
	Latitud_Cuadrante
	Longitud_Cuadrante
	Fecha
	Cantidad_Elementos
Variables de red	Cantidad_Usuarios
	Antiguedad_Red
	Expansion_Red
	Velocidad_Viento_Ms
	Temperatura_Media_C
Variables climáticas	Humedad_Relativa_Pct
	Temperatura_Minima_C
	Temperatura_Maxima_C
	Precipitacion_Total_Mm
	Duracion
Variables objetivo	Frecuencia

Número de observaciones. La tabla consolidada final se estima como

$$\text{Total de observaciones} = 47,649 \times 1,826 = 87,007,074,$$

correspondiente a cinco años de información a nivel elemento-día.

Procedencia de la información

Origen de la información. La empresa origen de los datos operativos y técnicos es **Centrales Eléctricas de Norte de Santander S.A E.S.P (Cens S.A E.S.P)**.

Lugar donde se registra la información. Sistemas corporativos (BRAE, OMS y GIS). Para variables climatológicas se utiliza la fuente institucional externa Nasa Power.

La información se registra en la red de distribución eléctrica de Norte de Santander, con soporte de localización geográfica por activo y por cuadrante.

Metodología

Nuestra metodología está organizada por etapas que se alinean con los objetivos específicos del proyecto. El enfoque general consiste en integrar datos, limpiarlos, analizarlos y construir modelos para predecir los indicadores *SAIDI* y *SAIFI* de la empresa de distribución eléctrica en Norte de Santander.

Se decidió utilizar CRISP-DM (Cross-Industry Standard Process for Data Mining) como marco de referencia por ser un estándar reconocido en la industria para proyectos de ciencia de datos [ref45](#), el cual fue adaptado al contexto específico del sector eléctrico regulado. Las fases de CRISP-DM se implementaron de la siguiente manera: el entendimiento del negocio (Business Understanding) se desarrolla en las Secciones [5.1](#) a [5.4](#), donde se describen el problema, los objetivos y la justificación. Las fases de entendimiento y preparación de datos (Data Understanding y Data Preparation) corresponden a las Etapas 1 a 4, en Secciones [5.1](#), [5.2](#), [5.3](#) y [5.4](#), en las que se integran, depuran, exploran los datos y se construyen las variables analíticas. La fase de modelado y evaluación (Modeling y Evaluation) se desarrolla en la Etapa 5, en la Sección [5.5](#), donde se construyen y validan los modelos predictivos. Finalmente, el despliegue (Deployment) corresponde a la Etapa 6 en la Sección [5.6](#), en la cual se consolidan los resultados, se documenta el proceso y se entrega código reproducible.

Esta adaptación de CRISP-DM considera los requisitos específicos del regulador (CREG, SSPD), las métricas propias del sector eléctrico (*SAIDI*, *SAIFI*) y la necesidad de que los modelos sean interpretables para su uso en la toma de decisiones.

5.1. Etapa 1 – Extracción de datos

Objetivo específico asociado: OE1

Esta etapa comprende la recolección, integración y estandarización de las fuentes de datos internas (SCADA, OMS, GIS, CIS, registros de fallas y mantenimiento) y externas (NASA, CREG, SSPD). Incluye la creación de un repositorio analítico unificado y la elaboración de un catálogo de datos que documenta metadatos, alcances, limitaciones y métricas de integridad.

Entregable: Informe de consolidación de datos y catálogo de calidad e integridad.

Fuentes de información

A partir del año 2023, la Electrificadora de Norte de Santander realizó una migración de su sistema de gestión de interrupciones. Como resultado, la recopilación de información de interrupciones eléctricas se llevó a cabo a partir de dos bases de datos provenientes de sistemas distintos:

- **OMS Energy:** sistema utilizado hasta antes de la migración, del cual se extrae la información histórica de interrupciones previas a 2023.
- **OMS SP7 de Siemens:** nuevo sistema implementado desde 2023, del cual se obtiene la información de interrupciones a partir de dicha fecha.

Esta dualidad de fuentes implica diferencias estructurales en los esquemas de datos (tales como nombres de campos, codificaciones y niveles de granularidad), las cuales fueron consideradas durante el proceso de integración y homologación de la información.

5.1.1. Sistemas y fuentes consultadas

Se integran datos de cinco fuentes de información principales:

- **BRAE:** base regulatoria e histórica de eventos.
- **OMS SPARD** (sistema histórico): fuente de elemento causante antes de la migración.
- **OMS SP7** (sistema actual): fuente de elemento causante en archivos CSV mensuales.
- **GTECH (GIS):** inventario y georreferenciación de activos eléctricos.
- **NASA POWER (API):** serie diaria de variables climatológicas por coordenada/cuadrante.

5.1.2. Extracción base y depuración de eventos de interrupción (BRAE)

La construcción de la base de eventos de interrupción se realizó a partir de la tabla transaccional `BRAE.QA_TFDDREGISTRO`, la cual contiene el registro histórico de eventos de desconexión del sistema eléctrico. A partir de esta fuente, se ejecutó una consulta SQL orientada a depurar inconsistencias, restringir el periodo de análisis y estandarizar la estructura del identificador de evento.

En primer lugar, se seleccionaron únicamente los campos relevantes para el análisis: el identificador del evento (FDD_CODIGOEVENTO), la fecha de inicio de la desconexión (FDD_FINICIAL) y la fecha de reconexión (FDD_FFFINAL). Adicionalmente, se incluyó un campo vacío para ELEMENTO_FALLADO, con el fin de mantener compatibilidad estructural con otras fuentes que sí contienen este nivel de desagregación.

Posteriormente, se aplicaron criterios de depuración y filtrado. En primer lugar, se restringió la muestra al periodo comprendido entre los años 2021 y 2025, garantizando consistencia temporal del análisis. En segundo lugar, se excluyeron aquellos registros marcados como no relevantes mediante la variable FDD_EXCLUSION, conservando únicamente los eventos clasificados como NO EXCLUIDA. En tercer lugar, se eliminaron eventos asociados a causas no válidas según la regulación (FDD_CAUSA_SSPD NOT IN (1)), así como aquellos registros sin fecha de finalización (FDD_FFFINAL IS NOT NULL), los cuales no permiten calcular la duración del evento.

Finalmente, se utilizó la instrucción DISTINCT para garantizar la eliminación de duplicados en el identificador de evento, obteniéndose una base depurada y consistente a nivel de evento de interrupción. Como resultado de este proceso de extracción y limpieza, se obtuvo un total de 95,280 registros válidos de eventos de desconexión para el periodo de análisis.

```
1  SELECT DISTINCT FDD_CODIGOEVENTO AS ID_EVENTO
2      ,FDD_FINICIAL AS FECHA_DESCONEXION
3      ,FDD_FFFINAL AS FECHA_CONEXION
4      ,'' AS ELEMENTO_FALLADO
5  FROM BRAE.QA_TFDDREGISTRO
6  WHERE TO_CHAR(FDD_FINICIAL,'YYYY') IN ('2021', '2022', '2023', '2024', '
7      2025')
8      AND FDD_EXCLUSION = 'NO EXCLUIDA'
9      AND FDD_CAUSA_SSPD NOT IN (1)
10     AND FDD_FFFINAL IS NOT NULL;
```

Tabla 5.1: Muestra de eventos depurados de interrupción (BRAE)

ID EVENTO	FECHA DESCONEXION	FECHA CONEXION	ELEMENTO FALLADO
801851	14/03/21 06:59:00.000	14/03/21 09:30:00.000	(null)
787583	04/01/21 08:50:00.000	04/01/21 17:15:00.000	(null)
787496	03/01/21 14:18:14.296	03/01/21 14:40:42.699	(null)
787232	01/01/21 10:29:33.936	01/01/21 13:30:00.000	(null)
787455	03/01/21 10:34:23.000	03/01/21 13:30:00.000	(null)
787376	02/01/21 12:09:22.000	02/01/21 18:20:00.000	(null)
789756	16/01/21 08:50:00.000	16/01/21 15:50:00.000	(null)
788677	10/01/21 08:37:45.000	10/01/21 10:10:00.000	(null)
788932	12/01/21 06:47:47.000	12/01/21 08:30:00.000	(null)
787922	06/01/21 08:42:00.000	06/01/21 15:28:00.000	(null)

5.1.3. Extracción de afectación por evento

Con el fin de complementar la base de eventos de interrupción, se construyó una tabla de afectación asociada a cada evento, incorporando información sobre el número de elementos afectados y la cantidad de usuarios impactados. Este proceso permite pasar de una caracterización puramente temporal del evento a una medición de su severidad en términos de impacto en la red.

La extracción se realizó a partir de la tabla `BRAE.QA_TFDDREGISTRO`, la cual se utilizó como fuente principal de eventos, y se complementó mediante una unión (`LEFT JOIN`) con la base `QA_TTC1`, que contiene información asociada a la conexión de transformadores y el número de usuarios por conexión.

En particular, la variable `CANTIDAD_USUARIOS` se construyó a partir del conteo de usuarios asociados a cada transformador (`TC1_CODCONEX`) agrupados por periodo, mientras que la variable de afectación por evento se obtuvo mediante la agregación de estos usuarios a nivel de evento de interrupción.

Posteriormente, se aplicaron los mismos criterios de depuración utilizados en la etapa anterior, restringiendo el análisis al periodo 2021–2025, excluyendo eventos marcados como no relevantes (`FDD_EXCLUSION = 'NO EXCLUIDA'`), eliminando causas no válidas según la clasificación regulatoria (`FDD_CAUSA_SSPD NOT IN (1)`) y conservando únicamente registros con fecha de finalización válida (`FDD_FFIAL IS NOT NULL`).

Finalmente, los datos se agregaron a nivel de evento (`FDD_CODIGOEVENTO`) utilizando la función `GROUP BY`, obteniendo como resultado dos indicadores clave: el número de elementos fallados por evento y el total de usuarios afectados. El procedimiento permitió consolidar una base consistente de 95,280 registros, alineada con la estructura del conjunto de eventos previamente depurado.

```

1  SELECT FDD_CODIGOEVENTO AS ID_EVENTO
2      ,COUNT(FDD_CODIGOELEMENTO) AS CANTIDAD_ELEMENTOS_FALLADOS
3      ,SUM(CANTIDAD_USUARIOS) AS CANTIDAD_USUARIOS
4  FROM BRAE.QA_TFDDREGISTRO
5  LEFT JOIN (
6      SELECT TC1_CODCONEX AS TRANSFORMADOR
7          ,COUNT(TC1_CODCONEX) AS CANTIDAD_USUARIOS
8          ,TC1_PERIODO AS PERIODO
9      FROM QA_TTC1
10     WHERE SUBSTR(TC1_PERIODO, 1, 4) IN ('2021', '2022', '2023', '2024', '
2025')
11     GROUP BY TC1_PERIODO, TC1_CODCONEX
12 ) ON FDD_CODIGOELEMENTO = TRANSFORMADOR
13 AND FDD_PERIODO_TC1 = PERIODO
14 WHERE TO_CHAR(FDD_FINICIAL,'YYYY') IN ('2021', '2022', '2023', '2024', '
2025')
15 AND FDD_EXCLUSION = 'NO EXCLUIDA'
16 AND FDD_CAUSA_SSPD NOT IN (1)
17 AND FDD_FFAL IS NOT NULL
18 GROUP BY FDD_CODIGOEVENTO;
19

```

Tabla 5.2: Muestra de afectación por evento (BRAE + QA_TTC1)

ID EVENTO	CANTIDAD ELEMENTOS FALLADOS	CANTIDAD USUARIOS AFECTADOS
795044	33	2692
795513	162	11796
788221	10	74
788203	240	3865
789543	8	45
789719	109	503
789929	109	503
788758	1	6
798712	159	1869

5.1.4. Extracción del elemento causante histórico

Con el objetivo de identificar el elemento de la red asociado a la causa de cada evento de maniobra, se realizó la extracción de información histórica desde la base de datos del sistema OMS (Outage Management System), específicamente desde la tabla OMS.MANIOBRAS@SPARD. Esta fuente permite complementar la información de eventos de interrupción mediante la identificación del elemento físico que originó la falla.

El proceso de extracción se centró en dos variables principales: el código de la maniobra (CODE), utilizado como identificador del evento en el sistema OMS, y el elemento fallado (BREAKER), que corresponde al activo de la red asociado a la causa de la interrupción. Estas variables permiten establecer la relación entre el evento registrado y el componente físico responsable dentro de la infraestructura eléctrica.

Adicionalmente, se aplicaron criterios de filtrado temporal y de calidad de datos. En primer lugar, se restringió la información a registros con fecha igual o posterior al año 2021, garantizando la consistencia histórica del análisis. En segundo lugar, se excluyeron aquellos eventos clasificados como pruebas operativas mediante la condición `CAUSA != 'PRUEBA'`, con el fin de conservar únicamente eventos reales de operación del sistema.

Como resultado de este proceso de extracción y depuración, se obtuvo una base de datos estructurada a nivel de maniobra, la cual permite complementar la trazabilidad entre eventos de interrupción y los elementos físicos de la red asociados a su ocurrencia.

```

1  SELECT CODE AS CODIGO_MANIOBRA
2      ,BREAKER AS ELEMENTO_FALLADO
3  FROM OMS.MANIOBRAS@SPARD
4  WHERE TO_NUMBER(TO_CHAR(FECHA, 'YYYY')) >= 2021
5        AND CAUSA != 'PRUEBA';
6

```

Tabla 5.3: Muestra de elemento causante histórico (OMS SPARD)

CODIGO MANIOBRA	ELEMENTO FALLADO
640011	AMVE271
634924	LMVEL79620
634978	LMVEL67393
631108	RMVEL79067-2
631464	CMVE2454
631761	SW6844
637873	BMVE749
640442	LMVEL99259
631793	SANC52

5.1.5. Extracción del elemento causante actual

Con el objetivo de actualizar la información histórica del sistema de maniobras, se realizó la extracción de los datos correspondientes a la versión más reciente del sistema OMS en formato plano (CSV). Este proceso permite comple-

mentar la información histórica con registros operativos actuales, garantizando la continuidad y consistencia de la base de datos utilizada en el análisis.

La extracción se realizó mediante un proceso de lectura y depuración de datos en Python, a partir del archivo fuente correspondiente a la versión actual del sistema. En primer lugar, se cargó el archivo mediante la función `read_csv`, asegurando la correcta lectura de la estructura tabular. Posteriormente, se realizó una limpieza de los nombres de las columnas mediante la eliminación de espacios en blanco al inicio y al final, con el fin de evitar inconsistencias en la identificación de variables.

A continuación, se seleccionaron únicamente las variables relevantes para el análisis: `Maniobra Apertura`, `Tipo Elemento` y `Elemento_Falla`. Esta selección permitió homogenizar la estructura de la base con la información histórica previamente construida. Finalmente, se eliminaron los registros duplicados mediante la función `drop_duplicates`, garantizando la unicidad de las observaciones a nivel de combinación de variables relevantes.

Como resultado, se obtuvo una base depurada y estandarizada del sistema OMS actual, la cual es consistente con la estructura de la base histórica y permite su integración en el proceso de consolidación del dataset final.

```

1  columnas_necesarias = ['Maniobra Apertura', 'Tipo Elemento', '
2  Elemento_Falla']
3  df = pd.read_csv(ruta_actual)
4  df.columns = df.columns.str.strip()
5  df = df[columnas_necesarias].drop_duplicates()

```

Tabla 5.4: Muestra de elemento causante actual (OMS SP7)

MANIOBRA APERTURA	TIPO ELEMENTO	ELEMENTO FALLA
424000000000114424	Transformador de distribucion	1T07942
124000000000269842	Fusible	F1979
124000000000269842	Transformador de distribucion	F1979
124000000000273378	Fusible	F2004
124000000000269851	Fusible	F2000
124000000000273383	Fusible	F2001
124000000000273374	Fusible	F2006
124000000000273377	Fusible	F2004
124000000000273372	Fusible	F2006
124000000000273356	Fusible	F2005
124000000000273381	Fusible	F1993

5.1.6. Extracción de inventario GIS

Con el propósito de incorporar la dimensión espacial de la red eléctrica, se realizó la extracción del inventario georreferenciado a partir del sistema GIS corporativo. Esta información permite asociar cada activo de la red con sus coordenadas geográficas y características físicas, facilitando posteriormente el análisis espacial de los eventos de interrupción.

La extracción se efectuó desde la base de datos `ccomun@gtech`, la cual contiene el inventario técnico de los activos de la red. A partir de esta fuente, se seleccionaron las variables correspondientes al identificador del elemento (`nodo_transform_v`), la latitud (`coor_gps_lat`), la longitud (`coor_gps_lon`) y la altitud (`coor_z`). Adicionalmente, se incluyó la variable `ubicacion`, que permite complementar la caracterización espacial del activo.

Asimismo, se definió explícitamente el tipo de activo como `Transformador`, con el fin de estandarizar la clasificación dentro del conjunto de datos integrado. Esta homogenización resulta clave para la posterior vinculación con los eventos de interrupción y la construcción del panel activo-día.

Como resultado, se obtuvo una base georreferenciada de los activos de la red, la cual constituye un insumo fundamental para el enriquecimiento espacial del dataset consolidado.

```

1  SELECT
2      nodo_transform_v AS ELEMENTO,
3      coor_gps_lat     AS LATITUD,
4      coor_gps_lon     AS LONGITUD,
5      coor_z           AS ALTITUD,
6      'Transformador' AS TIPO,
7      ubicacion
8  FROM ccomun@gtech c
9  JOIN cconectividad_e@gtech USING (g3e_fid)
10 WHERE c.estado = 'OPERACION'
11      AND c.g3e_fno = 20400
12 UNION
13 SELECT
14     r.codigo          AS ELEMENTO,
15     coor_gps_lat      AS LATITUD,
16     coor_gps_lon      AS LONGITUD,
17     coor_z            AS ALTITUD,
18     'Reconectador'   AS TIPO,
19     ubicacion
20  FROM ereconec_at@gtech r
21  JOIN ccomun@gtech c USING (g3e_fid)
22  JOIN cconectividad_e@gtech USING (g3e_fid)
23  WHERE c.estado = 'OPERACION';
24

```

Tabla 5.5: Muestra de inventario georreferenciado de activos (GIS GTECH)

ELEMENTO	LATITUD	LONGITUD	ALTITUD	TIPO
2T01558	6.960719612	-72.18029066	636	Transformador
2T01557	6.972762106	-72.18726993	743	Transformador
2T01467	6.973200989	-72.15472768	815	Transformador
2T01466	6.978510343	-72.14903608	726	Transformador
F3199	6.978980206	-72.19049387	832	Aisladero
PSW8910	6.978980206	-72.19049387	832	Aisladero
2T01555	6.982222682	-72.19495813	825	Transformador
2T01554	6.982742594	-72.20226264	867	Transformador
2T01556	6.984663810	-72.18619273	727	Transformador
2T01465	6.985402944	-72.13537905	530	Transformador
F3192	6.987527091	-72.20044897	767	Aisladero
PSW8909	6.987527091	-72.20044897	767	Aisladero
F5217	6.991040416	-72.20123180	726	Aisladero
PSW8908	6.991040416	-72.20123180	726	Aisladero
2T01553	6.991242376	-72.19636467	679	Transformador
2T01470	6.991396285	-72.15644527	790	Transformador
ESW6924	6.992103744	-72.13486380	453	Aisladero
F5211	6.992103744	-72.13486380	453	Aisladero
2T01471	6.992290614	-72.13485446	453	Transformador
2T01469	6.993224220	-72.14776723	656	Transformador
F8201	6.997255476	-72.12409341	361	Aisladero

Y así sucesivamente para Interruptor, Cuchilla, Aisladero, Reconectador y Transformador.

5.1.7. Extracción de variables meteorológicas

Con el objetivo de incorporar condiciones climáticas como variables explicativas en el análisis de interrupciones del sistema eléctrico, se realizó la extracción de información meteorológica a partir de la plataforma NASA POWER. Esta fuente proporciona series temporales diarias de variables climáticas relevantes, las cuales permiten capturar la influencia del entorno atmosférico sobre la ocurrencia y duración de eventos en la red.

El proceso de extracción se centró en un conjunto de variables meteorológicas seleccionadas por su relevancia en el análisis de confiabilidad del sistema eléctrico. En particular, se consideraron las variables de precipitación total (PRECTOT), temperatura media (T2M), temperatura máxima (T2M_MAX), temperatura mínima (T2M_MIN), humedad relativa (RH2M) y velocidad del viento (WS2M).

```
1 parametros_nasa = ("PRECTOT", "T2M", "T2M_MAX", "T2M_MIN",
2 "RH2M", "WS2M")
```


Tabla 5.6: Muestra de variables meteorológicas (NASA POWER) - Parte 1

VEL. VIENTO	TEMP. MEDIA	HUMEDAD	TEMP. MIN	TEMP. MAX	PRECIP.
2.06	13.27	87.24	9.12	18.63	2.6
2.66	13.89	88.27	10.71	18.92	1.41
1.93	13.66	88.59	10.29	18.96	3.04
1.73	13.6	85.07	9.13	20.17	9.07
1.45	11.52	69.12	5.95	18.7	0.79
1.1	12.29	80.8	7.55	17.76	0.77
1.76	13.23	88.9	10.65	17.93	3.03
2.34	12.95	88.44	10.14	17.84	2.51
2.41	12.69	87.38	9.48	16.55	1.84
2.98	12.99	90.13	9.65	17.44	3.35
3.18	13.12	87.67	10.58	17.69	0.9

Estas variables fueron extraídas a nivel diario para el periodo comprendido entre el 1 de enero de 2021 y el 31 de diciembre de 2025, lo que dio lugar a una base de aproximadamente 83.5 millones de registros. Este volumen de información refleja la estructura panelizada de la base climática, construida mediante la combinación de múltiples variables atmosféricas observadas diariamente a lo largo del horizonte temporal de análisis.

La incorporación de estas variables permite enriquecer el dataset consolidado con condiciones exógenas del entorno, facilitando el análisis de su relación con la frecuencia y severidad de las interrupciones en el sistema eléctrico.

5.1.8. Resumen metodológico de extracción e integración de bases de datos

Lógica de in La Tabla 5.7 sintetiza el proceso de extracción e integración desarrollado en la Etapa 1. En conjunto, se consolidaron seis fuentes complementarias: BRAE como base transaccional de eventos de interrupción; BRAE + QA_TTC1 para cuantificar la severidad operativa (usuarios afectados); OMS SPARD y OMS SP7 para identificar el elemento causante y fallado en los periodos pre y post migración del sistema; GIS (GTECH) para incorporar la georreferenciación de activos de red; y NASA POWER para enriquecer el análisis con variables climáticas diarias. Cada fuente fue sometida a reglas explícitas de filtrado, homologación y depuración, lo que permitió obtener bases consistentes y trazables que constituyen el insumo inicial para la integración del panel descrita en la Etapa 2.

Tabla 5.7: Resumen metodológico de extracción e integración de bases de datos

Fuente	Variables principales	Proceso aplicado	Resultado
BRAE (QA_TFDDREGISTRO)	ID EVENTO, FECHA DESCONEXION, FECHA CONEXION	Filtrado temporal (2021–2025), exclusión de registros no válidos, eliminación de duplicados	95.280 eventos de interrupción
BRAE + QA_TTC1	CANTIDAD USUARIOS, ELEMENTOS DE CONEXION	JOIN por elemento y periodo, agregación por evento	Base de severidad por evento (usuarios)
OMS SPARD (histórico)	CODIGO MANIOBRA, ELEMENTO FALLADO, ELEMENTO CAUSANTE	Filtrado de registros desde 2021, exclusión de pruebas	Base histórica de causa de falla
OMS SP7 (actual)	MANIOBRA APERTURA, TIPO ELEMENTO, CANTIDAD ELEMENTOS FALLADOS, ELEMENTO FALLA	Lectura CSV, limpieza de columnas, eliminación de duplicados	Base actualizada de elementos causantes
GIS (GTECH)	ELEMENTO, LATITUD, LONGITUD, ALTITUD, TIPO	Extracción desde sistema georreferenciado corporativo	Inventario espacial de la red
NASA POWER	PRECTOT, T2M, T2M_MAX, T2M_MIN, RH2M, WS2M	Extracción diaria (2021–2025) por variables climáticas	83.5 millones de registros meteorológicos

5.2. Etapa 2 - Integración y depuración de datos

5.2.1. Lógica de integración entre sistemas

Una vez extraídas y depuradas las fuentes descritas en la Etapa 5.1, la integración se ejecuta de forma secuencial sobre tablas intermedias, preservando trazabilidad de llaves y evitando pérdida de emparejamiento entre sistemas con esquemas distintos (BRAE, OMS SPARD, OMS SP7, GIS y NASA POWER). La secuencia aplicada fue la siguiente.

5.2.1.1 Construcción de la tabla base de eventos (BRAE).

A partir de BRAE.QA_TFDDREGISTRO se genera la tabla `tabla_eventos` con `ID_EVENTO`, `FECHA_DESCONEXION` y `FECHA_CONEXION`, aplicando filtros regulatorios del periodo 2021–2025, exclusión de eventos no válidos y eliminación de duplicados. Esta tabla define el universo analítico de interrupciones (95,280 eventos).

5.2.1.2 Construcción de la tabla de afectación por evento (Tabla 5.2).

En la Sección 5.1.3 se construye la Tabla 5.2 de afectación por evento, la cual consolida las columnas `CANTIDAD_ELEMENTOS` y `CANTIDAD_USUARIOS` a nivel de `ID_EVENTO`. Su integración a la tabla base consolidada se realiza en el paso 5.2.1.5.

5.2.1.3 Completar ELEMENTO_FALLADO (OMS SPARD + OMS SP7).

La tabla base de eventos obtenida en la Sección 5.1.2 se construyó con el campo `ELEMENTO_FALLADO` vacío, reservado para su completamiento en la integración. Dado el cambio de sistema OMS en el año 2023, la información del elemento causante se extrajo de forma separada en dos fuentes: la Sección 5.1.4 (*Extracción del elemento causante histórico*, OMS SPARD) y la Sección 5.1.5 (*Extracción del elemento causante actual*, OMS SP7). En este paso, la tabla de la Sección 5.1.2 se cruza con ambas tablas OMS, aplicando en cada caso la lógica de emparejamiento definida en su extracción:

- **Histórico (Sección 5.1.4 – OMS SPARD):** cruce por `CODIGO_MANIOBRA` ↔ `ID_EVENTO` para completar `ELEMENTO_FALLADO` con el valor de `BREAKER` en eventos del periodo pre-migración.
- **Actual (Sección 5.1.5 – OMS SP7):** cruce por `MANIOBRA_APERTURA` ↔ `ID_EVENTO` para completar `ELEMENTO_FALLADO` con el valor de `ELEMENTO_FALLA`, junto con `TIPO_ELEMENTO`, en eventos del periodo post-migración.

5.2.1.4 Construcción de la tabla base consolidada (activo-día).

A partir de este paso se inicia la construcción de la tabla base consolidada del proyecto. Como insumo inicial se toma la Tabla 5.5 (inventario georreferenciado de activos obtenido en la Sección 5.1.6), del cual se conserva un registro por ELEMENTO ($A = 47,649$ activos únicos), y se cruza con un calendario diario comprendido entre el 2021-01-01 y el 2025-12-31 ($T = 1,826$ días), empleando el campo FECHA_DIA. Este cruce genera un producto cartesiano entre el universo de activos eléctricos y el horizonte temporal de análisis, con cardinal $N = A \times T = 47,649 \times 1,826 = 87,007,074$ observaciones, definiendo la estructura panel **activo** $\times$ **día** sobre la cual, en los pasos 5.2.1.5 a 5.2.1.8, se anexan los valores restantes de la secuencia de integración. El detalle del procedimiento para los pasos 5.2.1.4 a 5.2.1.8 se documenta en [Consolidada.html](#).

5.2.1.5 Integración de CANTIDAD_ELEMENTOS y CANTIDAD_USUARIOS (Tabla 5.2).

Sobre la tabla base consolidada obtenida en el paso 5.2.1.4, se integran las columnas CANTIDAD_ELEMENTOS y CANTIDAD_USUARIOS provenientes de la Tabla 5.2 (afectación por evento, Sección 5.1.3), mediante el siguiente cruce de llaves:

- ID_EVENTO = ELEMENTO

entre la Tabla 5.2 y la tabla del paso 5.2.1.4, incorporando al panel las métricas de severidad e impacto operativo asociadas a cada evento de interrupción. La integración se realiza mediante cruce izquierdo por (ELEMENTO, FECHA_DIA), de modo que el panel conserva $N = 87,007,074$ filas.

5.2.1.6 Integración de variables climáticas (NASA POWER).

Sobre la tabla resultante del paso 5.2.1.5 ($N = 87,007,074$ filas), se anexan las variables de la serie diaria nasa_power_consolidado mediante cruce izquierdo por (ELEMENTO, FECHA_DIA), incorporando precipitación, temperatura (media, máxima, mínima), humedad relativa y velocidad del viento, sin modificar el cardinal del panel.

5.2.1.7 Agregación de variables objetivo (DURACION y FRECUENCIA).

En este paso se construyen las columnas DURACION y FRECUENCIA sobre la tabla resultante del paso 5.2.1.6 ($N = 87,007,074$ filas). Para ello, se agregan previamente los eventos de la Tabla 5.1 (Sección 5.1.2) a nivel (COMPONENTE_FALLADO, FECHA_DIA) y el resultado se integra al panel mediante cruce izquierdo por (ELEMENTO, FECHA_DIA). La Tabla 5.1 contiene

los campos `FECHA_DESCONEXION` y `FECHA_CONEXION`. Con base en las fechas de desconexión y reconexión, se asignan los valores diarios de la siguiente forma:

- **DURACION** (minutos): duración del evento prorrateada por día. Cuando un evento abarca varios días, su duración se reparte entre cada `FECHA_DIA` según los minutos que el evento ocupa dentro de ese día (intersección del intervalo `[FECHA_DESCONEXION, FECHA_CONEXION]` con cada día calendario). Así, el día de inicio recibe los minutos desde `FECHA_DESCONEXION` hasta la medianoche, los días intermedios reciben 1,440 min cada uno, y el día de cierre recibe los minutos desde la medianoche hasta `FECHA_CONEXION`.
- **FRECUENCIA**: número de desconexiones cuyo inicio (`FECHA_DESCONEXION`) ocurre en `FECHA_DIA` (no se prorratea; se cuenta en el día de inicio).

Cuando el activo no presenta interrupciones en un día, se asigna `DURACION = 0` y `FRECUENCIA = 0`. El cruce exige que `COMPONENTE_FALLADO` coincida con `ELEMENTO` del inventario `tipo_elemento.csv` (Tabla 5.5), el cual emplea el **código de sitio** georreferenciado. Cuando OMS registra el **código del activo** reemplazado en lugar del código de sitio, el emparejamiento falla y el evento no se propaga al panel espacial (Sección 5.3.5).

5.2.1.8 Consolidación del panel final (activo–día).

Sobre la tabla base consolidada definida en el paso 5.2.1.4, y una vez anexados los valores de los pasos 5.2.1.5 a 5.2.1.7, se obtiene el dataset final con grano **activo eléctrico × día** y $N = 87,007,074$ observaciones ($A = 47,649$ activos $\times T = 1,826$ días). En días sin falla se registra `DURACION = 0`, `FRECUENCIA = 0`, `CANTIDAD_ELEMENTOS = 0` y `CANTIDAD_USUARIOS = 0`.

La base de datos consolidada se estructura como un panel de datos de tipo activo–tiempo, donde la unidad muestral corresponde a un **activo eléctrico observado diariamente**. En términos formales, cada observación se identifica mediante el par (i, t) , donde i denota el activo eléctrico y t el día dentro del periodo de análisis. Bajo esta estructura, el conjunto de datos permite capturar la evolución temporal de cada activo a lo largo del horizonte de estudio.

Sea A el número total de activos eléctricos en la red y T el número total de periodos diarios observados, el tamaño teórico del panel balanceado está dado por:

$$N = A \times T$$

donde:

- $A = 47,649$ corresponde al número de activos eléctricos únicos en la Tabla 5.5 (inventario GIS, un registro por ELEMENTO),
- $T = 1,826$ corresponde al número de días observados (cinco años de información diaria).

En consecuencia, el número total de observaciones en la base consolidada se calcula como:

$$N = 47,649 \times 1,826 = 87,007,074$$

5.2.2. Diagrama de flujo de la secuencia de integración

Este diagrama de flujo resume visualmente la secuencia de integración y la estructura del panel final, como guía para el lector, especificando las relaciones entre las tablas y las operaciones aplicadas en cada paso.




Figura 5.1: Estructura del panel de datos activo-día

5.2.3. Descripción de la tabla base consolidada

Las Tablas 5.8 a 5.11 presentan una muestra de la tabla base consolidada resultante del paso 5.2.1.8, con grano **activo eléctrico** $\times$ **día**. Por limitaciones de ancho en la página, la muestra se divide en cuatro bloques consecutivos que

conservan el mismo orden de filas: identificación del activo (Tabla 5.8), severidad y clima inicial (Tabla 5.9), clima complementario (Tabla 5.10) y variables de continuidad (Tabla 5.11).

Tabla 5.8: Muestra de la tabla base consolidada (grano activo-día) – Parte 1: activo y fecha

ID ACTIVO	TIPO	LAT.	LON.	ALT.	FECHA DIA
AASW4819	Aisladero	8.5786778	-72.92349	219	01/01/2021
1T12452	Transformador	8.5839989	-72.92248	241	01/01/2021
REC21365	Reconectador	8.5840628	-72.92246	241	01/01/2021
CUC12345	Cuchilla	7.7523729	-73.23971	1236	01/01/2021
INT39845	Interruptor	7.7476080	-73.25551	1359	02/01/2021
AASW4820	Aisladero	7.7561057	-73.26037	1169	02/01/2021
1T12453	Aisladero	7.7409332	-73.20825	1636	02/01/2021
REC21366	Transformador	7.7428641	-73.18990	1542	02/01/2021
CUC12346	Reconectador	7.7538839	-73.17721	1707	03/01/2021

Tabla 5.9: Muestra de la tabla base consolidada (grano activo-día) – Parte 2: severidad y clima inicial (continuación)

ID ACTIVO	FECHA DIA	C. ELEM.	C. USU.	VEL. VIENTO	TEMP. MED.
AASW4819	01/01/2021	0	0	1.11	23.91
1T12452	01/01/2021	0	0	1.23	24.58
REC21365	01/01/2021	125	2015	0.96	23.04
CUC12345	01/01/2021	0	0	0.81	23.02
INT39845	02/01/2021	0	0	1.05	23.83
AASW4820	02/01/2021	0	0	1.12	24.08
1T12453	02/01/2021	0	0	1.08	24.52
REC21366	02/01/2021	0	0	1.26	24.37
CUC12346	03/01/2021	0	0	1.41	24.34

Tabla 5.10: Muestra de la tabla base consolidada (grano activo-día) – Parte 3: clima complementario (continuación)

ID ACTIVO	FECHA DIA	HUM. REL.	TEMP. MIN.	TEMP. MAX.	PRECIP.
AASW4819	01/01/2021	78.91	20.06	29.98	3.19
1T12452	01/01/2021	75.79	20.27	30.90	1.31
REC21365	01/01/2021	83.94	20.26	27.82	3.19
CUC12345	01/01/2021	79.55	17.92	30.09	7.28
INT39845	02/01/2021	69.70	19.35	30.79	1.99
AASW4820	02/01/2021	61.99	17.20	30.81	0.98
1T12453	02/01/2021	72.16	20.38	30.59	2.70
REC21366	02/01/2021	75.50	20.18	30.63	3.29
CUC12346	03/01/2021	74.34	20.40	30.43	1.86

Tabla 5.11: Muestra de la tabla base consolidada (grano activo-día) – Parte 4: variables de continuidad (continuación)

DURACION	FRECUENCIA
0	0
0	0
4.215	3
0	0
0	0
0	0
0	0
0	0
0	0

Nota: las filas de las Tablas 5.8 a 5.11 corresponden al mismo conjunto de observaciones en el mismo orden. Los registros sin interrupción en el día presentan DURACION = 0 y FRECUENCIA = 0.

5.2.4. Descripción de las variables

Tabla 5.9 (severidad y clima inicial). Las columnas ID ACTIVO y FECHA DIA se repiten en esta tabla para facilitar la trazabilidad de filas entre bloques consecutivos. Las variables propias de este bloque son:

- **C. ELEM. (CANTIDAD_ELEMENTOS):** número de elementos de red afectados por el evento de interrupción asociado al activo en el día. Proviene de la Tabla 5.2 (afectación por evento, Sección 5.1.3) e integra al panel en el paso 5.2.1.5. Cuando el activo no registra falla en el día, el valor es 0. **Clasificación:** cuantitativa discreta.
- **C. USU. (CANTIDAD_USUARIOS):** número de usuarios afectados por el evento de interrupción vinculado al activo en el día. Se obtiene de la misma fuente y mediante el mismo cruce que CANTIDAD_ELEMENTOS, y constituye una medida de severidad operativa del impacto sobre la demanda. En días sin interrupción, el valor es 0. **Clasificación:** cuantitativa discreta.
- **VEL. VIENTO (WS2M):** velocidad del viento a 2 m de altura, expresada en m/s. Corresponde a la variable WS2M de NASA POWER (Sección 5.1.7) e integra al panel por FECHA_DIA en el paso 5.2.1.6. **Clasificación:** cuantitativa continua.
- **TEMP. MED. (T2M):** temperatura media del aire en el día, expresada en °C. Proviene del parámetro T2M de NASA POWER y captura las condiciones térmicas promedio del entorno asociadas a cada observación activo-día. **Clasificación:** cuantitativa continua.

Tabla 5.10 (clima complementario). Al igual que en la Tabla 5.9, ID ACTIVO y FECHA DIA permiten alinear filas entre tablas. Las variables climáticas restantes del bloque son:

- **HUM. REL. (RH2M):** humedad relativa del aire a 2 m, expresada en porcentaje (%). Proviene del parámetro RH2M de NASA POWER e integra al panel por FECHA_DIA. **Clasificación:** cuantitativa continua.
- **TEMP. MIN. (T2M_MIN):** temperatura mínima diaria del aire, expresada en °C. Corresponde al parámetro T2M_MIN de NASA POWER y complementa la temperatura media con el extremo inferior del rango térmico del día. **Clasificación:** cuantitativa continua.
- **TEMP. MAX. (T2M_MAX):** temperatura máxima diaria del aire, expresada en °C. Proviene del parámetro T2M_MAX de NASA POWER y representa el extremo superior del rango térmico observado en el día. **Clasificación:** cuantitativa continua.
- **PRECIP. (PRECTOT):** precipitación total acumulada en el día, expresada en mm. Corresponde al parámetro PRECTOT de NASA POWER y permite incorporar la exposición del activo a condiciones de lluvia en la fecha de observación. **Clasificación:** cuantitativa continua.

Tabla 5.11 (variables de continuidad). Este bloque concentra las variables objetivo del análisis, construidas en el paso 5.2.1.7 a partir de la Tabla 5.1 (eventos depurados, Sección 5.1.2) y de los campos FECHA_DESCONEXION y FECHA_CONEXION:

- **DURACION (DURACION, en minutos):** duración total del evento de interrupción, calculada como la diferencia entre FECHA_CONEXION y FECHA_DESCONEXION y asignada al día de FECHA_DESCONEXION (sin prorrateo entre días calendario). En días sin falla, el valor es 0. **Clasificación:** cuantitativa continua.
- **FRECUENCIA (FRECUENCIA):** número de interrupciones del activo cuyo inicio (FECHA_DESCONEXION) ocurre en FECHA_DIA. La frecuencia se contabiliza únicamente en el día de ocurrencia del evento. En días sin falla, el valor es 0. **Clasificación:** cuantitativa discreta.

Objetivo específico asociado: OE1

Una vez construido el panel consolidado (pasos de integración 5.2.1.4–5.2.1.8), se deriva la tabla agregada por cuadrante y semana (Sección 5.2.5). La Etapa 2 cierra con la evidencia institucional de calidad de las fuentes (Sección 5.2.7). El

diagnóstico de completitud del panel, la identificación de valores extremos y el resto del análisis exploratorio se desarrollan en la Etapa 3; la imputación, el tratamiento definitivo de atípicos y la preparación del dataset para modelado, en la Etapa 4.

5.2.5. Agrupación de data consolidada por semana y cuadrante

Definición del grano analítico (cuadrante $\times$ semana)

El panel consolidado con grano **activo eléctrico $\times$ día** ($N = 87,007,074$ observaciones) constituye la base de integración y trazabilidad del proyecto: preserva la relación uno a uno entre cada activo de red y cada día del horizonte 2021–2025, y permite reconstruir con rigor la secuencia de pasos descrita en la Sección 5.2.1. No obstante, el objetivo del estudio —pronosticar el comportamiento de *SAIDI* y *SAIFI* en distintas áreas del territorio de concesión— exige una unidad de análisis de mayor agregación espacial y temporal, coherente con la lectura regulatoria y operativa de los indicadores de continuidad del servicio.

Desde el punto de vista espacial, los indicadores de calidad se interpretan y gestionan a escala territorial (zonas de concentración, circuitos y áreas de servicio), no a nivel de un activo aislado. Para sintetizar el comportamiento de la red en unidades homogéneas del territorio, se adopta la malla institucional de **800 cuadrantes** que cubre el área de concesión de la red eléctrica. En esta malla, el sufijo **_800** identifica la versión del esquema con 800 divisiones espaciales; cada celda tiene dimensiones aproximadas de $5 \times 2,5$ km. Cada activo eléctrico se asigna a un **id_cuadrante** mediante el catálogo **ELEMENTO_FALLA_CUADRANTE_800**, de modo que las observaciones diarias de múltiples activos ubicados en la misma celda puedan consolidarse en una métrica zonal. La Figura 5.2 ilustra la estructura de esta partición espacial sobre el área de estudio.

Desde el punto de vista temporal, la granularidad diaria del panel es necesaria para la integración de eventos, clima y severidad, pero resulta excesivamente ruidosa para el análisis exploratorio espacial y para la modelación orientada a dinámicas semanales de continuidad y clima. Por ello, se define la **semana calendario** (con inicio en lunes) como periodo de agregación temporal, lo que permite suavizar fluctuaciones diarias, estabilizar las series de interrupción y alinear las covariables meteorológicas en un horizonte compatible con la gestión operativa y con visualizaciones espacio-temporales (mapas por cuadrante y series semanales).

Bajo esta definición, la unidad muestral del dataset agregado es el par (**cuadrante, semana**). El panel `data_consolidada.csv` se conserva como insumo base y referencia del proyecto; la tabla derivada `data_agrupada_por_cuadrante_semana.csv` constituye la representación analítica para los análisis territoriales posteriores,




Figura 5.2: Malla de 800 cuadrantes sobre el territorio de concesión (celdas de aprox. $5 \times 2,5$ km).

sin sustituir ni alterar el panel diario original.

Procedimiento de agregación

Con el panel consolidado `data_consolidada.csv`, se construyó la tabla de análisis a grano **cuadrante** $\times$ **semana**. El procedimiento se documenta en [data_agrupacion.html](#).

El insumo principal es el panel del paso 5.2.1.8. Para asignar cada activo a su zona de análisis espacial, se utiliza el catálogo `ELEMENTO_FALLA_CUADRANTE_800`, del cual se extrae la relación `ELEMENTO` $\rightarrow$ `id_cuadrante` (campo `CUADRANTE_1`). La asignación se integra al panel mediante cruce izquierdo por `ELEMENTO`, conservando todas las filas del panel y anexando el identificador de cuadrante cuando existe emparejamiento. Complementariamente, el archivo `CUADRANTE_CORD_800` aporta la referencia de centroides por cuadrante.

Sobre el panel enriquecido, cada observación diaria se asigna a una semana calendario mediante `floor_date(FECHA_DIA, unit = "week", week_start = 1)`, de modo que la semana inicia en lunes. La duración diaria en horas se obtiene como `DURACION_min / 60`, coherente con la unidad en minutos definida en el paso 5.2.1.7.

La agregación se ejecuta con `group_by(id_cuadrante, semana)` y las siguientes reglas de resumen:

- **Coordenadas del cuadrante** (latitud, longitud, altitud): primer valor

registrado en el grupo (`first`), tomado del inventario georreferenciado del panel.

- **Impacto operativo:** `usuarios_afectados = sum(CANTIDAD_USUARIOS)` y `elementos_afectados = sum(CANTIDAD_ELEMENTOS)` en la semana, acumulando los conteos diarios de los activos del cuadrante.
- **Variables climáticas semanales:** `temp_media_semana` y `humedad_media_semana` como promedio; `temp_max_semana` y `viento_max_semana` como máximo; `temp_min_semana` como mínimo; `viento_medio_semana` como promedio; `precip_total_semana` como suma de la precipitación diaria.
- **Continuidad del servicio:** `n_eventos = sum(FRECUENCIA)` (total de desconexiones iniciadas en la semana) y `duracion_total = sum(duracion_horas)` (suma de horas de interrupción prorrateadas por día en el cuadrante).

El resultado se exporta como `data_agrupada_por_cuadrante_semana.csv` en la ruta definida por la variable de entorno `UBICACION_DATA`.

5.2.6. Descripción de la tabla base semanal cuadrante

La Tabla 5.12 resume la estructura del dataset agregado `data_agrupada.csv`, con grano **cuadrante** $\times$ **semana**. Cada fila corresponde a un par (`id_cuadrante`, `semana`) y concentra, para esa celda de la malla y ese periodo semanal, las coordenadas de referencia, el impacto operativo acumulado, las variables climáticas resumidas y las métricas de continuidad del servicio. Las Tablas 5.13 a 5.16 presentan una muestra ilustrativa; por limitaciones de ancho en la página, la muestra se divide en cuatro bloques consecutivos que conservan el mismo orden de filas: identificación espacio-temporal e impacto operativo (Tabla 5.13), temperatura (Tabla 5.14), clima complementario (Tabla 5.15) y continuidad del servicio (Tabla 5.16).

Nota: las filas de las Tablas 5.13 a 5.16 corresponden al mismo conjunto de observaciones en el mismo orden. `duracion_total` se expresa en horas (suma semanal de `DURACION_min/60` prorrateada por día). Las semanas sin interrupciones registran `n_eventos = 0` y `duracion_total = 0`. Las unidades de temperatura, humedad, viento y precipitación coinciden con las del panel diario ($^{\circ}\text{C}$, %, m/s y mm, respectivamente).

5.2.7. Evidencia de calidad y confiabilidad de las fuentes

La validación de los datos recopilados por Centrales Eléctricas de Norte de Santander S.A. E.S.P. (CENS) se fundamenta en su arquitectura institucional de gestión, enmarcada en la Política de Gestión de Tecnología de la Información (Sesión de la Junta Directiva No. 800 del 20 de febrero de 2018) [37] y en la

Tabla 5.12: Estructura de la tabla base semanal cuadrante (data_agrupada.csv).

Bloque	Variables	Regla de agregación
Identificación	id_cuadrante	Llave del grupo
Georreferencia	semana	first
	latitud	
	longitud	
Impacto	altitud	sum
	usuarios_afectados	
Clima	elementos_afectados	mean
	temp_media_semana	
	temp_max_semana	max
	temp_min_semana	min
	humedad_media_semana	mean
	viento_medio_semana	mean
	viento_max_semana	max
	precip_total_semana	sum
Continuidad	n_eventos	sum
	duracion_total	

Tabla 5.13: Muestra de la tabla base semanal cuadrante (grano cuadrante-semana) – Parte 1: cuadrante, semana, coordenadas e impacto operativo

ID CUAD.	SEMANA	LAT.	LON.	ALT.	USU. AFECT.	ELEM. AFECT.
1	28/12/2020	7.0012	-72.6855	3418	0	0
1	04/01/2021	7.0012	-72.6855	3418	0	0
3	04/01/2021	7.1548	-72.7196	2850	0	0
12	11/01/2021	7.4521	-72.8903	1240	842	18
45	18/01/2021	7.7539	-73.1204	890	0	0
117	25/01/2021	7.9215	-72.5021	286	1254	24
203	01/02/2021	8.0812	-72.4108	312	0	0
45	08/02/2021	7.7539	-73.1204	890	315	6
117	15/02/2021	7.9215	-72.5021	286	680	11

Tabla 5.14: Muestra de la tabla base semanal cuadrante (grano cuadrante-semana) – Parte 2: temperatura (continuación)

ID CUAD.	SEMANA	TEMP. MED.	TEMP. MAX.	TEMP. MIN.
1	28/12/2020	13.6	19.8	6.2
1	04/01/2021	12.8	18.5	5.8
3	04/01/2021	13.1	19.2	6.0
12	11/01/2021	22.4	28.6	16.8
45	18/01/2021	23.8	30.1	18.2
117	25/01/2021	24.1	30.4	18.9
203	01/02/2021	24.5	30.8	19.1
45	08/02/2021	23.5	29.7	17.8
117	15/02/2021	24.3	30.2	18.6

Tabla 5.15: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 3: clima complementario (continuación)

ID CUAD.	SEMANA	HUM. MED.	VEL. MED.	VEL. MAX.	PRECIP.
1	28/12/2020	82.4	1.15	2.31	18.5
1	04/01/2021	80.1	1.08	2.18	12.3
3	04/01/2021	81.6	1.12	2.25	15.7
12	11/01/2021	76.3	0.98	1.95	8.4
45	18/01/2021	74.8	1.05	2.10	6.2
117	25/01/2021	73.5	1.18	2.42	9.8
203	01/02/2021	72.9	1.22	2.55	4.1
45	08/02/2021	75.2	1.09	2.08	11.6
117	15/02/2021	74.1	1.14	2.35	7.3

Tabla 5.16: Muestra de la tabla base semanal cuadrante (grano cuadrante–semana) – Parte 4: continuidad del servicio (continuación)

N EVENTOS	DURACION TOTAL (h)
0	0.0
0	0.0
0	0.0
5	28.4
0	0.0
8	41.7
0	0.0
2	12.6
4	22.3

Política del Sistema de Gestión Integrado (Sesión de la Junta Directiva No. 831 del 22 de abril de 2020) [38], orientadas a garantizar una gestión sistemática de calidad continua, sostenibilidad ambiental y cumplimiento legal mediante la evaluación permanente de la calidad de los datos, priorizando consistencia, disponibilidad y accesibilidad de la información [39].

CENS refuerza su gobernanza de datos mediante Instrumentos de Gestión de Información Pública, entre los cuales se destacan el Registro de Activos de Información (IPR), utilizado para detectar, clasificar y almacenar conjuntos de datos institucionales; los Cuadros de Clasificación Documental; el Esquema de Publicación de Información (IPS); el Índice de Información Clasificada y Reservada; los Costos de Reproducción; y el Programa de Gestión Documental (PGD). Estos instrumentos enmarcan el proceso institucional de almacenamiento, organización, acceso, difusión, protección y preservación de la información [40].

En conjunto, estos mecanismos reflejan sistemas de control interno, gobernanza, confianza en la información documentada y transparencia institucional. Asimismo, evidencian el funcionamiento estructurado de los registros y su disponibilidad operativa, garantizando la calidad, veracidad y consistencia de los datos utilizados en este estudio para la toma de decisiones analíticas y gerenciales.

La fiabilidad técnica de las fuentes climáticas y ambientales está respaldada por el IDEAM, entidad pública responsable de la recopilación oficial de datos hidrológicos, meteorológicos y ambientales en Colombia. El IDEAM opera bajo la Política Institucional para la Gestión de Información Estadística (E-SGI-PI003) [41] y las disposiciones del Sistema Estadístico Nacional, que establecen normas obligatorias de trazabilidad, control de calidad, validación estadística, metadatos estructurados y consistencia metodológica en los procesos de captura, procesamiento y difusión de datos [42].

Adicionalmente, en cumplimiento del Decreto 1081 de 2015, el Decreto 103 de 2015, la Ley 1712 de 2014 (Ley de Transparencia) y la Resolución 1519 de 2020 del MINTIC, el IDEAM garantiza que la información publicada sea auditable, actualizada y accesible, respaldada por canales institucionales de difusión, monitoreo interno e integridad documental. Estas disposiciones fortalecen la calidad estadística y aseguran que las series climáticas oficiales cumplan criterios formales de confiabilidad, oportunidad y validez técnica a escala nacional [8], [41], [42].

5.3. Etapa 3 – Análisis descriptivo y exploratorio de datos (EDA)

Objetivo específico asociado: OE2

Objetivo: comprender el comportamiento de los datos e identificar patrones, relaciones y comportamientos relevantes que orienten las decisiones de modelado.

Una vez completadas las etapas de extracción e integración (Etapas 1 y 2), se desarrolla un análisis exploratorio orientado a caracterizar las distribuciones de las variables, diagnosticar la calidad del panel (valores faltantes y extremos), identificar patrones temporales y espaciales, y evaluar las relaciones entre co-variables que podrían explicar la variación de *SAIDI* y *SAIFI*. Esta etapa se concibe como un análisis diagnóstico previo al modelamiento, orientado a garantizar la estabilidad e interpretabilidad de los resultados y a fundamentar las decisiones de imputación y transformación de la Etapa 4.

Para las variables cuantitativas se calculan medidas de tendencia central y dispersión, así como la proporción de valores atípicos; adicionalmente se construyen histogramas y diagramas de caja para examinar la forma de las distribuciones. En el caso de las variables categóricas, se analizan las frecuencias absolutas y relativas de cada categoría. El grado de asociación entre variables cuantitativas se evalúa mediante el coeficiente de correlación de Spearman y entre variables cualitativas mediante el estadístico de Cramér, con el fin de identificar redundancias y relaciones preliminares que orienten la depuración de variables en la Etapa 4. Las visualizaciones incluyen series de tiempo, gráficos de dispersión, mapas temáticos y mapas de calor de correlaciones.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes. Tras la caracterización del panel, se documentan el diagnóstico de datos faltantes (Sección 5.3.1) y la identificación de valores extremos (Sección 5.3.2); a continuación se profundiza en estadísticos descriptivos, distribuciones, patrones temporales y asociaciones entre variables. Sobre D_{mod} , la identificación de patrones y la visualización exploratoria (series de tiempo, gráficos de dispersión y mapas temáticos) se integran en la Sección 5.3.6.

5.3.1. Identificación de datos faltantes

Sobre el panel consolidado final (`data_consolidada.csv`), con $N = 87,007,074$ observaciones (grano activo eléctrico $\times$ día), se realizó un diagnóstico sistemático de valores faltantes (NA) con dos enfoques complementarios: (i) conteo de NA por variable y (ii) conteo de observaciones del panel con al menos un NA por fila. El objetivo fue cuantificar la magnitud y localizar el origen de la incompletitud como insumo del EDA y para fundamentar las decisiones de imputación o exclusión en la Etapa 4.

En el análisis por columna, para cada una de las 16 variables del panel se calculó el número absoluto de NA y su porcentaje respecto a N . En el análisis

por fila, se determinó cuántas observaciones (i, t) presentan cero, uno o más campos incompletos, junto con el máximo de variables faltantes registradas en una misma fila.

Los resultados muestran que la incompletitud se concentra en las variables climáticas integradas desde NASA POWER en el paso 5.2.1.6. Las seis variables meteorológicas (*velocidad_viento_ms*, *temperatura_media_c*, *humedad_relativa_pct*, *temperatura_minima_c*, *temperatura_maxima_c* y *precipitacion_total_mm*) presentan exactamente 3,401,838 valores faltantes cada una, equivalente al 3,91 % de N . Este patrón es coherente con el cruce izquierdo por (*ELEMENTO*, *FECHA_DIA*): las filas sin emparejamiento en la base climática conservan NA en el bloque meteorológico. La variable *ALTITUD* registra 32,868 faltantes (0,04 % de N), asociados al inventario GIS. El resto de variables del panel—identificación del activo (*ELEMENTO*, *TIPO*, *LATITUD*, *LONGITUD*), calendario (*FECHA_DIA*), severidad (*CANTIDAD_ELEMENTOS*, *CANTIDAD_USUARIOS*) y continuidad (*DURACION*, *FRECUENCIA*)—no presentan NA, dado que los pasos 5.2.1.5 y 5.2.1.7 asignan 0 en días sin evento.

A nivel de fila, 83,576,020 observaciones (96,06 %) están completas; 3,431,054 filas (3,94 %) tienen al menos un NA, y el máximo de variables incompletas en una misma observación es 7 (combinación de las seis variables climáticas más *ALTITUD*). La Figura 5.3 resume el porcentaje de faltantes por variable, ordenado de mayor a menor.




Figura 5.3: Porcentaje de valores faltantes por variable en el panel consolidado ($N = 87,007,074$).

En síntesis, la calidad estructural del panel es alta en variables operativas de interrupción (sin NA), y la incompletitud relevante para el modelado se limita al bloque climático y, en menor medida, a *ALTITUD*. Las reglas de imputación o exclusión se definen con base en este diagnóstico y se aplican en la Etapa 4.

Tabla 5.17: Resumen de valores faltantes por variable en el panel consolidado

Variable	<i>n</i> de NA	% sobre <i>N</i>
velocidad_viento_ms	3,401,838	3,91
temperatura_media_c	3,401,838	3,91
humedad_relativa_pct	3,401,838	3,91
temperatura_minima_c	3,401,838	3,91
temperatura_maxima_c	3,401,838	3,91
precipitacion_total_mm	3,401,838	3,91
ALTITUD	32,868	0,04
<i>Resto de variables del panel: 0 NA (0 %)</i>		

Tabla agrupada cuadrante $\times$ semana. Sobre la tabla de análisis `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90,128$ observaciones y 16 variables, se replicó el mismo esquema de diagnóstico: conteo de NA por variable y por fila. El procedimiento se documenta en [missing_values_grouped.html](#).

En el análisis por columna, las 16 variables del grano agregado—identificación y calendario (`id_cuadrante`, `semana`), georreferenciación (`latitud`, `longitud`, `altitud`), severidad (`usuarios_afectados`, `elementos_afectados`), clima semanal (`temp_media_semana`, `temp_max_semana`, `temp_min_semana`, `humedad_media_semana`, `viento_medio_semana`, `viento_max_semana`, `precip_total_semana`) y continuidad (`n_eventos`, `duracion_total`)—registran 0 valores faltantes (0 % sobre N_{agr}). A nivel de fila, las 90,128 observaciones están completas: ninguna fila presenta al menos un NA y el máximo de variables incompletas por fila es 0.

Este resultado es coherente con la agregación descrita en la Sección 5.2.5: las sumas y promedios semanales emplean `na.rm = TRUE`, de modo que los NA del panel diario no se propagan como campos vacíos en el grano agregado; las métricas operativas sin evento se consolidan en 0, y cada fila exportada conserva llaves estructurales definidas (`id_cuadrante`, `semana`). La Figura 5.4 ilustra la ausencia de faltantes en una muestra de las primeras 50 filas: todas las celdas se clasifican como completas.

En consecuencia, la tabla agrupada no requiere reglas de imputación por valores faltantes en la Etapa 4; el tratamiento de incompletitud documentado en los párrafos anteriores aplica al panel consolidado activo $\times$ día, grano en el que se originan los NA climáticos y de ALTITUD.

5.3.2. Identificación de valores extremos en variables cuantitativas

Se evaluó la presencia de valores extremos en las variables cuantitativas mediante reglas univariadas y diagramas de caja e histogramas. El análisis distingue observaciones operativamente plausibles de posibles inconsistencias de registro, sin aplicar aún transformaciones ni exclusiones definitivas; el tratamiento se di-




Figura 5.4: Mapa de faltantes por fila y variable en la tabla agrupada cuadrante $\times$ semana ($N_{agr} = 90,128$; muestra de 50 filas).



fiere a la Etapa 4 con base en estos hallazgos. Para cada variable se aplicaron tres reglas: (i) rango intercuartílico de Tukey, $[Q_1 - 1,5 \text{ IQR}, Q_3 + 1,5 \text{ IQR}]$; (ii) rango ampliado con factor 3,0; y (iii) percentiles P1–P99.

Panel consolidado activo $\times$ día. Sobre `data_consolidada.csv` ($N = 87,007,074$) se aplicó el protocolo descrito, excluyendo coordenadas geográficas (LATITUD, LONGITUD, ALTITUD). El detalle reproducible se documenta en [detection_outliers.html](https://detection-outliers.html).

Variables climáticas diarias. Las variables de temperatura y humedad presentan distribuciones aproximadamente simétricas y un porcentaje muy bajo de extremos bajo la regla de Tukey (entre 0 % para `humedad_relativa_pct` y 0,20 % para `temperatura_minima_c`); con el factor 3,0 prácticamente no se identifican extremos severos. La `precipitacion_total_mm` constituye la excepción: por su naturaleza fuertemente asimétrica y con exceso de ceros (días sin lluvia), la regla de Tukey marca el 10,38 % de las observaciones y la ampliada el 5,30 %, aunque la regla de percentiles solo señala el 1,00 %. Estos valores corresponden a días de lluvia intensa operativamente plausibles, no a errores de registro. La Tabla 5.18 resume estos resultados y las Figuras 5.5 y 5.6 muestran, respectivamente, los diagramas de caja y los histogramas sobre una muestra de 200,000 observaciones.

Tabla 5.18: Valores extremos en variables climáticas (panel completo)

Variable	Mediana	% IQR 1.5	% IQR 3.0	% P1-P99
velocidad_viento_ms	1,20	0,03	0,00	1,60
temperatura_media_c	25,47	0,02	0,00	1,99
humedad_relativa_pct	69,08	0,00	0,00	1,98
temperatura_minima_c	20,91	0,20	0,00	1,99
temperatura_maxima_c	31,32	0,05	0,00	1,99
precipitacion_total_mm	0,50	10,38	5,30	1,00


Figura 5.5: Diagramas de caja de las variables climáticas (muestra de 200,000 observaciones).

Figura 5.6: Histogramas de las variables climáticas (muestra de 200,000 observaciones).

Variables de severidad y continuidad diarias. Estas variables están dominadas por ceros (días sin interrupción): el 99,94 % de las filas registra 0, por lo que sobre el panel completo se cumple $Q_1 = Q_3 = 0$ y la regla de Tukey resulta poco informativa (marca como extremo cualquier día con evento, 0,06 % del panel). Por ello, el análisis relevante se realiza sobre los días con evento (valor > 0), donde se concentran 48,375 registros de afectación y 48,364 de continuidad. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha: la mediana de CANTIDAD_USUARIOS es 23 usuarios pero su máximo alcanza 34,622; la DURACION tiene mediana de 417 minutos (≈ 7 horas) y un máximo de 332,395 minutos (≈ 231 días), sugerente de posibles inconsistencias de registro que se marcan para revisión. La regla de Tukey marca entre el 9 % y el 15 % de los días con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 5.19 resume estos resultados y las Figuras 5.7 y 5.8 presentan los diagramas de caja e histogramas sobre los días con evento.

Tabla 5.19: Valores extremos en variables de severidad y continuidad (días con evento, valor > 0)

Variable	n	Mediana	Máximo	% IQR 1.5	% IQR 3.0
CANTIDAD_ELEMENTOS	48,375	2	2,469	14,91	11,78
CANTIDAD_USUARIOS	48,375	23	34,622	14,50	10,83
DURACION	48,364	417	332,395	8,94	5,36
FRECUENCIA	48,364	1	6	1,96	1,96




Figura 5.7: Diagramas de caja de las variables de severidad y continuidad en días con evento.

Tabla agrupada cuadrante $\times$ semana. Sobre `data_agrupada.csv` (Sección 5.2.5), con $N_{\text{agr}} = 90,128$ observaciones, se replicó el mismo esquema excluyendo




Figura 5.8: Histogramas de las variables de severidad y continuidad en días con evento. `id_cuadrante`, `latitud`, `longitud` y `altitud`. El procedimiento se documenta en [outliers_gruped.html](https://outliers-gruped.html).

Variables climáticas semanales. El diagnóstico se realizó sobre la tabla completa. Las variables de temperatura, humedad y viento presentan distribuciones aproximadamente simétricas y un porcentaje muy bajo de extremos bajo Tukey (entre 0 % y 0,03 %); con el factor 3,0 no se identifican extremos severos. La `precip_total_semana` constituye la excepción: al ser un acumulado semanal fuertemente asimétrico, la regla de Tukey marca el 8,98 % de las observaciones y la ampliada el 4,51 %, aunque la regla de percentiles solo señala el 1,00 %; estos valores corresponden a semanas de lluvia intensa operativamente plausibles. La Tabla 5.20 resume estos resultados y las Figuras 5.9 y 5.10 muestran los diagramas de caja y los histogramas sobre las 90,128 observaciones.

Tabla 5.20: Valores extremos en variables climáticas semanales (tabla agrupada)

Variable	Mediana	% IQR 1.5	% IQR 3.0	% P1-P99
<code>temp_media_semana</code>	24,84	0,00	0,00	1,95
<code>temp_max_semana</code>	32,76	0,00	0,00	1,99
<code>temp_min_semana</code>	18,95	0,03	0,00	1,96
<code>humedad_media_semana</code>	72,28	0,00	0,00	1,97
<code>viento_medio_semana</code>	0,91	0,00	0,00	1,99
<code>viento_max_semana</code>	1,29	0,00	0,00	1,69
<code>precip_total_semana</code>	618,8	8,98	4,51	1,00

Variables de severidad y continuidad. En la tabla completa persisten semanas sin interrupción registrada ($Q_1 = Q_3 = 0$ en `usuarios_afectados`, `elementos_afectados` y `n_eventos`), por lo que la regla de Tukey sobre el total




Figura 5.9: Diagramas de caja de las variables climáticas semanales en la tabla agrupada ($N_{\text{agr}} = 90,128$).




Figura 5.10: Histogramas de las variables climáticas semanales en la tabla agrupada ($N_{\text{agr}} = 90,128$).

es poco informativa para esas variables. El análisis relevante se realiza sobre semanas con evento (valor > 0), con 22,660–24,800 registros según la variable. En este subconjunto las distribuciones son fuertemente asimétricas a la derecha: la mediana de `usuarios_afectados` es 52 usuarios pero su máximo alcanza 69,928; `duracion_total` tiene mediana de 19,7 horas y un máximo de 2,227 horas (≈ 93 días acumulados en la semana). La regla de Tukey marca entre el 11,6 % y el 15,2 % de las semanas con evento como extremos, proporción esperable en distribuciones de cola pesada. La Tabla 5.21 resume estos resultados y las Figuras 5.11 y 5.12 presentan los diagramas de caja e histogramas.

Tabla 5.21: Valores extremos en severidad y continuidad (semanas con evento, valor > 0)

Variable	<i>n</i>	Mediana	Máximo	% IQR 1.5	% IQR 3.0
<code>usuarios_afectados</code>	22,660	52	69,928	15,16	11,21
<code>elementos_afectados</code>	22,660	7	3,626	15,00	10,70
<code>duracion_total</code>	24,800	19,7	2,227	11,56	4,25
<code>n_eventos</code>	22,659	1	58	14,53	5,73




Figura 5.11: Diagramas de caja de severidad y continuidad en semanas con evento (tabla agrupada).

En síntesis, en el grano cuadrante $\times$ semana los extremos climáticos son escasos y operativamente plausibles (con la precipitación acumulada marcada por asimetría natural), mientras que en severidad y continuidad la cola pesada refleja semanas de alta afectación o múltiples eventos en un mismo cuadrante. No se aplican transformaciones ni exclusiones en esta etapa; las decisiones de tratamiento se documentan y ejecutan en la Etapa 4 a partir de este diagnóstico sobre la tabla de análisis.




Figura 5.12: Histogramas de severidad y continuidad en semanas con evento (tabla agrupada).

5.3.3. Cálculo de estadísticos descriptivos

Tras el diagnóstico de completitud (Sección 5.3.1) y el análisis de valores extremos (Sección 5.3.2), se calculó un conjunto sistemático de estadísticos descriptivos sobre la tabla de análisis `data_agrupada.csv` (Sección 5.2.5), con $N_{agr} = 90,128$ observaciones cuadrante $\times$ semana. Se excluyeron las llaves y coordenadas (`id_cuadrante`, `latitud`, `longitud`, `altitud`) y se evaluaron las 11 variables numéricas de severidad, clima semanal y continuidad. El procedimiento reproducible se documenta en calculo_estadistico_descriptivo.html.

Para cada variable se reportaron: (i) medidas de tendencia central (media, mediana y moda); (ii) medidas de dispersión (rango, varianza, desviación estándar y coeficiente de variación); (iii) medidas de posición (cuartiles, deciles y percentiles P1, P5, P95 y P99); (iv) medidas de forma (asimetría y curtosis con exceso); y (v) distribución de frecuencias de la categoría derivada *actividad semanal del cuadrante*, construida a partir de `n_eventos` (sin eventos; 1 evento; 2–5 eventos; más de 5 eventos). Las Figuras 5.13 y 5.14 presentan la vista panorámica de las 11 variables mediante histogramas y diagramas de caja.

Variables climáticas semanales. Las siete variables meteorológicas agregadas presentan distribuciones aproximadamente simétricas y baja dispersión relativa: el coeficiente de variación (CV) se ubica entre 0,16 (`temp_max_semana`) y 0,81 (`viento_medio_semana`). La temperatura media semanal tiene mediana de 24,8 °C (media 23,8 °C; Q_1 – Q_3 : 20,4–27,2 °C) y asimetría cercana a cero (–0,37). La humedad relativa media semanal concentra la mediana en 72,3 % (CV = 0,16). La excepción es `precip_total_semana`: acumulado semanal con mediana de 618,8 mm, media de 1,942 mm, CV = 3,47 y fuerte asimetría positiva (30,6),




Figura 5.13: Histogramas de las variables numéricas de la tabla agrupada ($N_{\text{agr}} = 90,128$).




Figura 5.14: Diagramas de caja de las variables numéricas de la tabla agrupada ($N_{\text{agr}} = 90,128$).

coherente con semanas de lluvia intensa puntuales ($P99 = 18,217$ mm). La Tabla 5.22 resume tendencia central y dispersión; la Figura 5.15 muestra las curvas de densidad.

Tabla 5.22: Estadísticos descriptivos de variables climáticas semanales (tabla agrupada)

Variable	Media	Mediana	Desv. est.	CV	Asimetría
temp_media_semana	23,8	24,8	4,63	0,19	-0,37
temp_max_semana	31,9	32,8	5,30	0,17	-0,44
temp_min_semana	17,9	19,0	4,49	0,25	-0,49
humedad_media_semana	70,9	72,3	11,5	0,16	-0,36
viento_medio_semana	0,99	0,91	0,80	0,81	0,44
viento_max_semana	1,31	1,29	1,01	0,77	0,35
precip_total_semana	1,942	618,8	6,728	3,47	30,6




Figura 5.15: Curvas de densidad de las variables climáticas semanales ($N_{agr} = 90,128$).

Variables de severidad y continuidad. Las cuatro variables operativas están dominadas por ceros: la mediana de usuarios_afectados, elementos_afectados, n_eventos y duracion_total es 0 en el 74,9% de las semanas-cuadrante sin eventos registrados (Tabla 5.24). Cuando ocurre al menos un evento, las distribuciones son fuertemente leptocúrticas y con cola derecha pesada: usuarios_afectados alcanza un máximo de 69,928 usuarios (media 156,1; CV = 7,81); duracion_total un máximo de 2,227 horas acumuladas en la semana (media 13,7 h; CV = 3,67). La Tabla 5.23 resume las medidas principales; la Figura 5.18 presenta las densidades en escala $\log(1 + x)$ para semanas con evento.


En síntesis, el clima semanal exhibe comportamiento estable y casi simétrico,

Tabla 5.23: Estadísticos descriptivos de severidad y continuidad (tabla agrupada)

Variable	Media	Mediana	Máx.	CV	Asimetría	Q_3
usuarios_afectados	156,1	0	69,928	7,81	20,6	1
elementos_afectados	12,0	0	3,626	5,74	14,1	1
n_eventos	0,55	0	58	2,76	8,18	1
duracion_total	13,7	0	2,227	3,67	10,2	2,5



Tabla 5.24: Distribución de frecuencias por actividad semanal del cuadrante

Categoría (n_eventos)	Frec. absoluta	Frec. relativa (%)	Frec. acumulada (%)
Sin eventos	67,469	74,86	74,86
1 evento	12,115	13,44	88,30
2 a 5 eventos	9,246	10,26	98,56
Más de 5 eventos	1,298	1,44	100,00

**Figura 5.16:** Frecuencia de semanas-cuadrante según actividad de eventos ($N_{agr} = 90,128$).

Distribucion porcentual de semanas-cuadrante por actividad

N = 90,128 filas

**Figura 5.17:** Distribución porcentual de semanas-cuadrante por actividad de eventos.**Curvas de densidad — severidad y continuidad (semanas con evento)**Escala $\log(1+x)$ por la fuerte asimetría de estas variables**Figura 5.18:** Curvas de densidad de severidad y continuidad en escala $\log(1+x)$ (semanas con evento).

mientras que las variables operativas reflejan fuerte cero-inflación y colas pesadas propias del fenómeno de interrupciones. Estos perfiles —especialmente la asimetría de `precip_total_semana` y la concentración de semanas sin evento— orientan las transformaciones (p. ej. $\log(1 + x)$) y la selección de modelos en la Etapa 4.

5.3.4. Análisis de la distribución de variables

Con el propósito de comprender el comportamiento estadístico de las variables incluidas en el estudio, se realizó un análisis de distribución sobre las variables climáticas, de severidad y de continuidad contenidas en la tabla agregada cuadrante $\times$ semana ($N_{\text{agr}} = 90,128$; Sección 5.2.5). Para las variables cuantitativas se emplearon diagramas de densidad, complementados con indicadores de forma (asimetría, curtosis y proporción de ceros), lo que permitió evaluar simetría, dispersión, unimodalidad y presencia de valores extremos. El procedimiento reproducible se documenta en distribucion_variables.html.

Variables climáticas. Los resultados evidencian que las variables meteorológicas presentan distribuciones heterogéneas. Las temperaturas (media, máxima y mínima) y la humedad relativa muestran comportamientos estables, aproximadamente unimodales y con asimetría cercana a cero (entre $-0,49$ y $-0,36$), coherentes con las curvas de densidad presentadas en la Figura 5.15. En contraste, la precipitación acumulada semanal presenta una marcada asimetría positiva (coeficiente de $30,6$ y curtosis de $1,623$), caracterizada por una alta frecuencia de semanas con valores bajos de lluvia (el $9,1\%$ registra 0 mm) y un número reducido de observaciones con precipitaciones intensas. La Figura 5.19 contrasta la distribución en escala original y en escala $\log(1 + x)$: la transformación logarítmica aproxima la distribución a una forma simétrica, lo que anticipa su utilidad en la Etapa 4.

Variables de severidad y continuidad. Las variables asociadas a interrupciones del servicio (`usuarios_afectados`, `elementos_afectados`, `duracion_total` y `n_eventos`) muestran distribuciones altamente sesgadas hacia cero: la proporción de filas con valor 0 se ubica entre el $72,5\%$ (`duracion_total`) y el $74,9\%$ (resto de variables), como ilustra la Figura 5.20. Este comportamiento es esperado, dado que la mayor parte de las semanas-cuadrante no registra fallas. Sin embargo, condicionando a la ocurrencia de eventos (valor > 0), las distribuciones presentan colas derechas largas —con asimetrías entre $8,2$ y $20,6$ y curtosis entre 139 y 643 — que reflejan la existencia de incidentes de alta severidad con impacto significativo sobre la continuidad del servicio, según se aprecia en las




Figura 5.19: Distribución de la precipitación acumulada semanal en escala original y $\log(1 + x)$ ($N_{\text{agr}} = 90,128$).

densidades en escala $\log(1 + x)$ de la Figura 5.18.




Figura 5.20: Proporción de ceros en las variables de severidad y continuidad de la tabla agrupada.

En síntesis, el análisis de distribución confirma dos regímenes claramente diferenciados: un bloque climático estable y casi simétrico (con la precipitación como excepción asimétrica) y un bloque operativo cero-inflado con colas pesadas. Estos hallazgos fundamentan las transformaciones (p.ej. $\log(1 + x)$) y la consideración de modelos aptos para datos cero-inflados en la Etapa 4.

5.3.5. Análisis temporal de eventos

Para caracterizar la dinámica temporal de las interrupciones se construyó, a partir de la tabla agrupada `data_agrupada.csv` (Sección 5.2.5), la serie territorial semanal que consolida el total de `n_eventos` de todos los cuadrantes en cada semana calendario. La serie cubre 262 semanas del horizonte 2021–2025,

con una mediana de 124,5 eventos por semana (media 188,5; máximo 648). El procedimiento reproducible se documenta en [análisis_temporal_eventos.html](#).

Evolución de la serie semanal. La Figura 5.21 presenta la serie semanal con su tendencia suavizada (LOESS) sobre el horizonte exploratorio 2021–2025 (D_{EDA}). Se distinguen dos regímenes visuales: entre 2021 y 2023 la actividad se mantiene en un nivel bajo y relativamente estable, mientras que a partir de 2024 se observa un incremento sostenido del nivel de la serie. La agregación anual (Figura 5.22) cuantifica este cambio: de 5,167 eventos en 2021 y 4,934 en 2022, se pasa a 15,211 en 2024 y 18,199 en 2025; en términos de intensidad, el promedio asciende de ≈ 99 a ≈ 350 eventos por semana entre 2021 y 2025. La reinterpretación de este salto a la luz de la cobertura de integración se desarrolla en el párrafo siguiente (Sección 5.3.5).




Figura 5.21: Serie semanal de eventos de interrupción (suma sobre los cuadrantes) con tendencia LOESS, 2021–2025.




Figura 5.22: Total anual de eventos de interrupción sobre la tabla agrupada.

Diagnóstico de cobertura del emparejamiento evento–elemento. Al contrastar el conteo anual de eventos en `tabla_eventos_ajustado.csv` (BRAE) con la suma territorial de `n_eventos` en `data_agrupada.csv`, se identificó un **sesgo sistemático** en el grano espacial durante 2021–2023 (Tabla 5.25; Figura 5.23). La causa no es la ausencia del campo `COMPONENTE_FALLADO` —completo en el 100 % de los registros BRAE—, sino la **incompatibilidad entre esquemas de codificación** al cruzar eventos con el inventario georreferenciado `tipo_elemento.csv` (Tabla 5.5).

En la operación de la red coexisten dos identificadores para un mismo punto de conexión: (i) el **código de sitio** (ubicación), estable en el tiempo y empleado por el inventario GIS como `ELEMENTO`; y (ii) el **código de activo**, asociado al equipo instalado y **sujeto a cambio** cuando el activo se repone por mantenimiento o renovación, mientras el código de sitio permanece invariante. El panel consolidado y la agregación cuadrante $\times$ semana se construyen sobre el código de sitio. No obstante, en el sistema histórico OMS-SPARD (Sección 5.1.4) el elemento fallado (`BREAKER` $\rightarrow$ `COMPONENTE_FALLADO`) se registraba con frecuencia mediante el **código del activo** y no el del sitio. Ello impide el seguimiento histórico del punto de desconexión —unidad espacial central para el pronóstico territorial de *SAIDI* y *SAIFI* en esta tesis—, pues el cruce `COMPONENTE_FALLADO = ELEMENTO` no encuentra coincidencia en el inventario y el evento no genera `FRECUENCIA` en el panel activo $\times$ día.

El diagnóstico cuantitativo confirma esta hipótesis: la proporción de eventos cuyo `COMPONENTE_FALLADO` coincide con algún `ELEMENTO` de `tipo_elemento.csv` es del 30,5 % (2021), 30,9 % (2022) y 31,7 % (2023), valores cercanos a la cobertura del panel espacial en esos años (28,1 %, 28,1 % y 29,1 %, respectivamente). Con la migración a OMS-SP7 (Sección 5.1.5), la coincidencia asciende al 79,8 % (2024) y al 95,0 % (2025), acompañada por coberturas del panel del 77,7 % y 92,4 %. La Figura 5.22 debe interpretarse a la luz de esta brecha: el salto a partir de 2024 refleja en gran medida una **mayor homogeneización de la codificación** bajo OMS-SP7, y no únicamente un incremento operativo de interrupciones.

El procedimiento reproducible se documenta en [emparejamiento_eventos.html](#). Con base en este hallazgo —emergido en el presente análisis temporal— se define el **dataset de modelado** D_{mod} como el subconjunto de `data_agrupada.csv` con `year(semana)  $\in$  {2024, 2025}`, que comprende 36,120 filas cuadrante $\times$ semana, 105 semanas y 33,410 eventos georreferenciados en total (15,211 en 2024 y 18,199 en 2025). El horizonte 2021–2025 se conserva como D_{EDA} para las Secciones 5.3.1–5.3.5, pero **no** se empleará para estimar el modelo predictivo de la Etapa 4.

Tabla 5.25: Cobertura anual de la trazabilidad al inventario GIS y al panel espacial.

Año	Eventos BRAE	En inventario (%)	Panel espacial	Cobertura (%)
2021	18,398	30,5	5,167	28,1
2022	17,542	30,9	4,934	28,1
2023	20,068	31,7	5,845	29,1
2024	19,583	79,8	15,211	77,7
2025	19,689	95,0	18,199	92,4

Nota: “En inventario (%)” es la proporción de eventos cuyo COMPONENTE_FALLADO coincide con ELEMENTO en tipo_elemento.csv (código de sitio). “Panel espacial” es la suma anual de n_eventos en data_agrupada.csv. La brecha entre ambas columnas en 2021–2023 se atribuye al registro del código de activo —y no del código de sitio— en OMS-SPARD, lo que impide el seguimiento histórico del punto de desconexión. Los años 2024–2025 delimitan D_{mod} .




Figura 5.23: Comparación anual entre eventos BRAE y eventos reflejados en el panel espacial. Las etiquetas indican el porcentaje de cobertura respecto a BRAE; la brecha histórica se explica por la incompatibilidad entre el código de activo registrado en OMS-SPARD y el código de sitio del inventario GIS.

Estacionalidad intra-anual. La Figura 5.24 muestra la distribución de los totales semanales según el mes calendario. Se aprecia heterogeneidad estacional, con mayor actividad y dispersión en los meses asociados a temporadas de lluvia en la región, lo que es coherente con la influencia de la precipitación identificada en las Secciones 5.3.2 y 5.3.4.




Figura 5.24: Distribución del total semanal de eventos según mes calendario (2021–2025).

Autocorrelación temporal. Las funciones de autocorrelación simple y parcial de la serie semanal (Figura 5.25) evidencian fuerte persistencia: la autocorrelación es 0,92 en el rezago de una semana y decae lentamente (0,60 a 12 semanas; 0,38 a 26), manteniéndose significativa frente al intervalo de confianza del 95 % bajo ruido blanco ($\pm 0,12$). Adicionalmente, el rezago de 52 semanas conserva una autocorrelación de 0,43, indicativa de un componente estacional anual. Esta estructura justifica la incorporación de rezagos y términos estacionales como variables predictoras en la Etapa 4.

Evolución de la severidad y extensión territorial. La Figura 5.26 presenta las series semanales de usuarios afectados y duración acumulada: ambas acompañan el incremento de nivel observado en la frecuencia de eventos a partir de 2024, lo que indica que el cambio de régimen no es solo de conteo sino también de impacto sobre la continuidad del servicio. Complementariamente, la Figura 5.27 muestra el número de cuadrantes con al menos un evento por semana, que crece en paralelo: la mayor actividad reciente se distribuye sobre una porción más amplia del territorio y no se explica por unos pocos cuadrantes puntuales. En síntesis, el análisis temporal sobre D_{EDA} revela: (i) un cambio de nivel de la serie a partir de 2024, reinterpretado como mayor homogeneización de




Figura 5.25: ACF y PACF de la serie semanal de eventos (rezagos en semanas).




Figura 5.26: Evolución semanal de usuarios afectados y duración acumulada, con tendencia LOESS.




Figura 5.27: Número de cuadrantes con al menos un evento por semana (extensión territorial de la actividad).

la codificación activo/sitio bajo OMS-SP7 —y no como incremento operativo aislado—, lo que motiva la restricción del dataset de modelado a D_{mod} (2024–2025; Sección 5.3.5); (ii) estacionalidad intra-anual asociada al régimen de lluvias; y (iii) fuerte persistencia semanal con componente anual, que fundamenta el uso de rezagos temporales como predictores en D_{mod} . Estos hallazgos orientan la generación de ventanas temporales y la partición de datos de la Etapa 4.

Materialización de D_{mod} . Para operacionalizar la delimitación temporal sin alterar el insumo exploratorio, se construyó el archivo `data_agrupada_mod.csv` como subconjunto de `data_agrupada.csv` con filtro `year(semana) ∈ {2024, 2025}`, conservando el grano cuadrante $\times$ semana y el conjunto completo de variables climáticas y operativas. La tabla original 2021–2025 permanece intacta como D_{EDA} ; el resultado filtrado (36,120 filas; 344 cuadrantes; 105 semanas; 33,410 eventos) constituye el insumo analítico para las Secciones 5.3.6 en adelante y la Etapa 4, con partición natural entrenamiento 2024 / prueba 2025. El procedimiento reproducible —lectura, filtro, resumen por año y exportación— se documenta en consolidado_data_mod.html.

5.3.6. Identificación de patrones, tendencias y visualización exploratoria

Con fundamento en la delimitación de D_{mod} (Sección 5.3.5), se identifican patrones temporales, espaciales y de asociación clima–evento sobre la tabla `data_agrupada_mod.csv` (36,120 filas cuadrante $\times$ semana; 344 cuadrantes; 105 semanas; 33,410 eventos en 2024–2025). En esta misma subsección se integra la **visualización exploratoria** sobre D_{mod} : series de tiempo, diagramas de dispersión y mapas temáticos que complementan el análisis cuantitativo de patrones. El procedimiento reproducible se documenta en identificacion_patrones.html.

Patrones temporales. La Figura 5.28 presenta la serie semanal territorial de eventos en D_{mod} , con media de ≈ 318 eventos por semana. Aunque las etiquetas del eje horizontal se muestran cada 3 meses para facilitar la lectura, cada tramo de la línea corresponde a observaciones semanales consecutivas. La intensidad promedio asciende de 287 eventos/semana en 2024 a 350 en 2025. La estacionalidad mensual (Figura 5.29) confirma mayor actividad y dispersión en los meses asociados al régimen de lluvias, coherente con el análisis de §5.3.5 sobre D_{EDA} . La ACF de la serie semanal (Figura 5.30) mantiene persistencia elevada (rezago 1 = 0,80), lo que respalda el uso de rezagos como predictores en la Etapa 4.




Figura 5.28: Serie semanal de eventos sobre D_{mod} (2024–2025) con tendencia LOESS.




Figura 5.29: Estacionalidad mensual del total semanal de eventos en D_{mod} .

Patrones espaciales. El ranking de cuadrantes por total de n_{eventos} (Figura 5.31) y el mapa de intensidad territorial (Figura 5.33) evidencian heterogenei-




Figura 5.30: ACF y PACF de la serie semanal de eventos en D_{mod} .

dad espacial: los diez cuadrantes más activos concentran el 20,5 % de los eventos del periodo, mientras el 14,2 % de los cuadrantes (49 de 344) se clasifica en nivel de actividad *alta* (Figura 5.35). La actividad no se distribuye de forma uniforme sobre la malla de 800 cuadrantes, sino que se agrupa en zonas de mayor exposición operativa.




Figura 5.31: Quince cuadrantes con mayor número acumulado de eventos en D_{mod} .

La Figura 5.32 complementa el ranking anterior con la **ubicación geográfica** de los cuadrantes más activos sobre la malla territorial del área de estudio. Los recuadros resaltados corresponden a los primeros cuadrantes *top* del periodo 2024–2025 y muestran una concentración en cuatro zonas: (i) el área metropolitana de Cúcuta y Villa del Rosario; (ii) un corredor al suroccidente, en torno a Salazar, Arboledas, Durania y Chinácota; (iii) la subregión de Tibú, al norte del

departamento; y (iv) los municipios de Ocaña y Aguachica, al occidente. Esta distribución espacial confirma que la mayor actividad de interrupciones no es aleatoria, sino que se agrupa en núcleos urbanos y corredores de servicio de la red.




Figura 5.32: Ubicación geográfica de los cuadrantes *top* con mayor acumulado de eventos en D_{mod} (2024–2025). Los recuadros resaltados identifican la posición espacial de los primeros cuadrantes del ranking.

Patrones clima–evento. Mediante correlación de Spearman a nivel cuadrante $\times$ semana, la precipitación acumulada semanal (`precip_total_semana`) exhibe la asociación positiva más fuerte con `n_eventos` ($\rho = 0,41$; $p < 0,001$), seguida de variables de viento ($\rho \approx 0,14$). La Figura 5.34 ilustra la relación no lineal entre precipitación y frecuencia de eventos. Las temperaturas presentan asociaciones débiles y negativas ($|\rho| < 0,05$).

En síntesis, el análisis de patrones y la visualización exploratoria sobre D_{mod} confirman: (i) persistencia y estacionalidad temporal (series semanales, estacionalidad mensual y ACF); (ii) concentración espacial en un subconjunto de cuadrantes (ranking, mapa de intensidad y segmentación por actividad); y (iii) asociación positiva entre precipitación y frecuencia de interrupciones (correlación




Figura 5.33: Mapa de intensidad de eventos por cuadrante (2024–2025).




Figura 5.34: Dispersión entre precipitación semanal y $n_{eventos}$ por cuadrante en D_{mod} .




Figura 5.35: Segmentación de cuadrantes por nivel de actividad acumulada en D_{mod} .

de Spearman y diagrama de dispersión). Estos hallazgos orientan la selección de variables predictoras y la estratificación territorial de la Etapa 4. Los mapas de calor de correlaciones y el análisis multivariado formal se desarrollan en las Secciones 5.3.7 y 5.3.8.

5.3.7. Análisis de correlación y asociación

Con fundamento en los patrones preliminares de la Sección 5.3.6, se realizó un análisis sistemático de asociación pareada sobre `data_agrupada_mod.csv` (D_{mod} ; 36,120 filas cuadrante $\times$ semana). Dado el carácter asimétrico, cero-inflado y de colas pesadas de las variables operativas (Sección 5.3.4), se empleó el coeficiente de correlación de **Spearman** en lugar de Pearson. El procedimiento reproducible se documenta en [analisis_correlacion.html](#).

Matriz de asociación global. Se calcularon las correlaciones de Spearman entre las variables operativas (`n_eventos`, `usuarios_afectados`, `elementos_afectados`, `duracion_total`), las siete variables climáticas semanales y las coordenadas geográficas (`altitud`, `latitud`, `longitud`). La Figura 5.36 resume la submatriz clima-operativo. Los pares con mayor asociación absoluta del panel completo concentran redundancia operativa: `usuarios_afectados`–`elementos_afectados` ($\rho = 0,99$), `n_eventos`–`elementos_afectados` ($\rho = 0,98$) y `n_eventos`–`usuarios_afectados` ($\rho = 0,97$), coherentes con la co-ocurrencia de afectación y frecuencia en semanas con interrupción.

Bloque climático: redundancias. En el bloque meteorológico (Figura 5.37) se identificaron **nueve** pares con $|\rho| \geq 0,70$, principalmente entre temperaturas

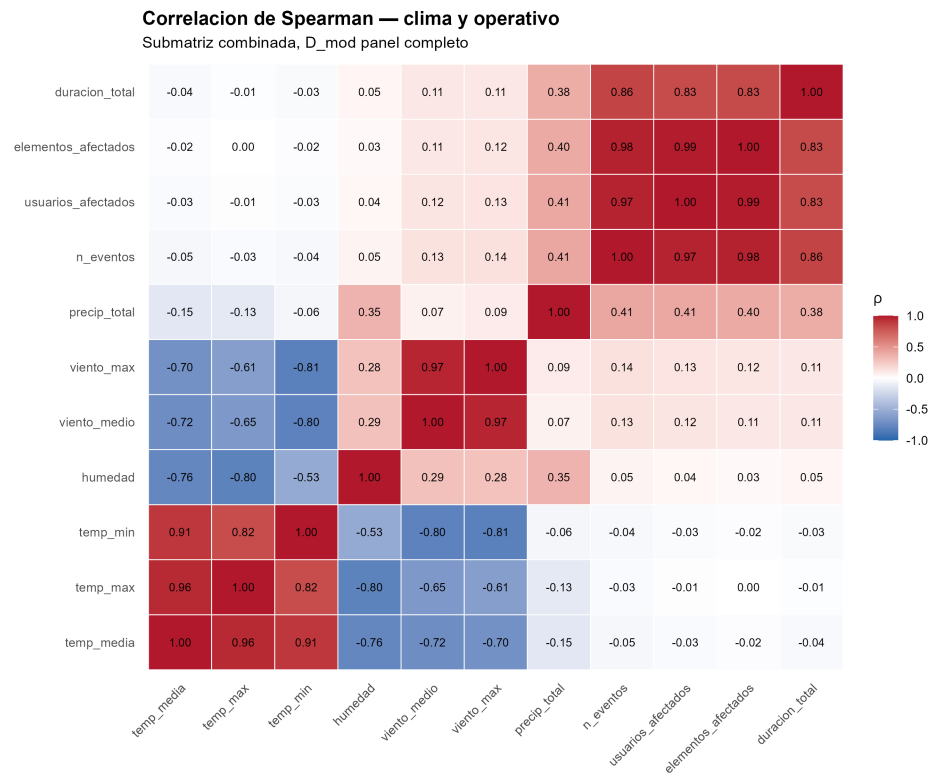


Figura 5.36: Mapa de calor de correlaciones de Spearman entre variables climáticas y operativas en D_{mod} .

(temp_media-temp_max: $\rho = 0,96$; temp_media-temp_min: $\rho = 0,91$) y entre componentes de viento ($\rho = 0,97$). Las temperaturas presentan además asociación negativa moderada con la humedad ($\rho \approx -0,80$) y con el viento ($\rho \approx -0,72$ a $-0,81$). Estos resultados anticipan **multicolinealidad** entre covariables climáticas y orientan la depuración de variables en la Etapa 4.

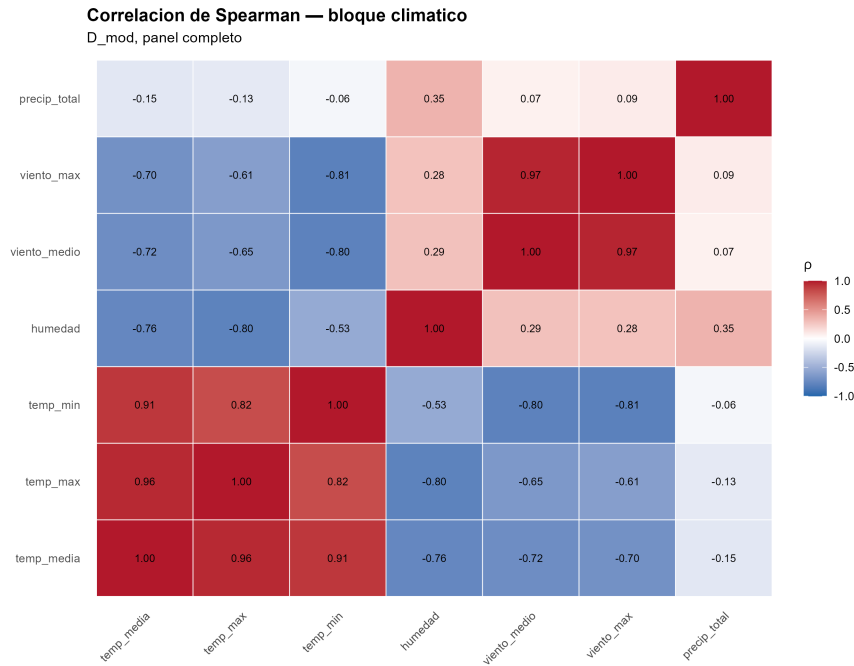


Figura 5.37: Correlaciones de Spearman en el bloque climático semanal (D_{mod}).

Bloque operativo. La Figura 5.38 muestra que las cuatro métricas de continuidad y severidad están fuertemente correlacionadas entre sí (ρ entre 0,83 y 0,99), aunque duracion_total exhibe una asociación algo menor con n_eventos ($\rho = 0,86$) que con las variables de afectación. Ello sugiere que frecuencia, alcance (usuarios_afectados, elementos_afectados) y magnitud temporal (duracion_total) capturan dimensiones parcialmente distintas del impacto operativo.

Clima → operativo. La Figura 5.39 y la Tabla 5.26 cuantifican la asociación entre covariables meteorológicas y métricas de interrupción. La precip_total_semana presenta la relación positiva más fuerte con n_eventos ($\rho = 0,41$; $p < 0,001$), seguida de asociaciones del mismo orden con usuarios_afectados ($\rho = 0,41$), elementos_afectados ($\rho = 0,40$) y duracion_total ($\rho = 0,38$). Las variables de viento muestran asociaciones positivas débiles ($\rho \approx 0,12$ – $0,14$), mientras las




Figura 5.38: Correlaciones de Spearman entre variables operativas en D_{mod} .

temperaturas y la humedad registran correlaciones cercanas a cero o ligeramente negativas ($|\rho| < 0,05$), en línea con el análisis exploratorio de la Sección 5.3.6.




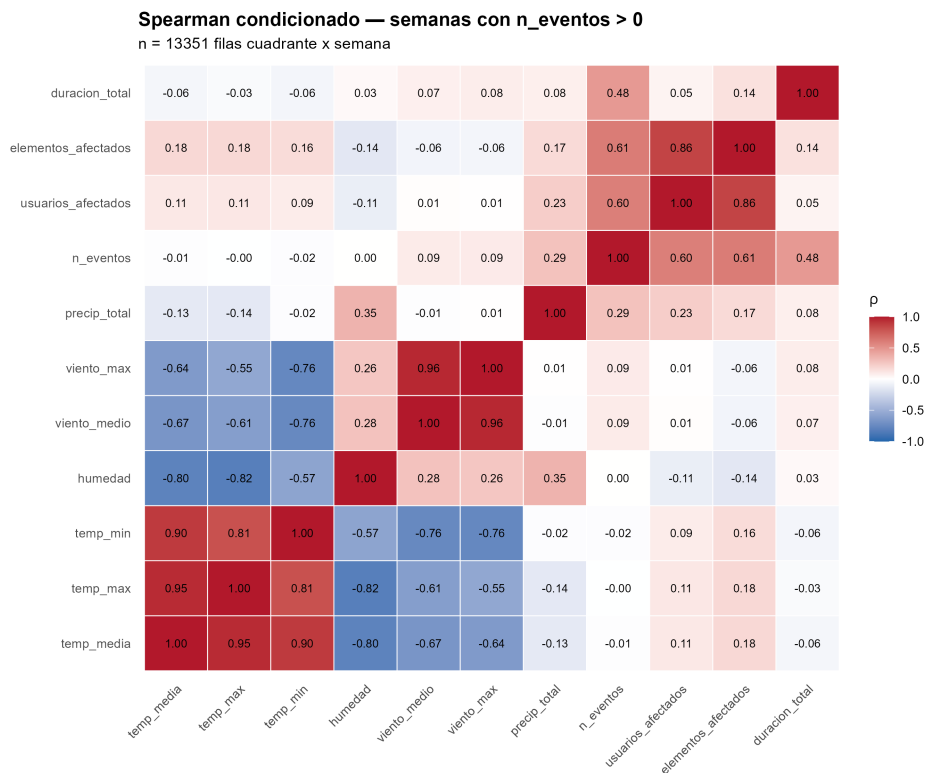
Figura 5.39: Coeficientes de Spearman entre variables climáticas y operativas en D_{mod} .

Análisis condicionado. Dado que el 63 % de las filas cuadrante $\times$ semana registra $n_{\text{eventos}} = 0$, se repitió el análisis sobre el subconjunto con al menos un evento (13,351 filas; 37 % del panel). En este régimen, la asociación precipitación–

Tabla 5.26: Asociación Spearman entre precipitación y variables operativas (D_{mod} ; panel completo)

Par de variables	Spearman ρ	p -valor
precip_total_semana $\leftrightarrow$ n_eventos	0,414	< 0,001
precip_total_semana $\leftrightarrow$ usuarios_afectados	0,406	< 0,001
precip_total_semana $\leftrightarrow$ elementos_afectados	0,399	< 0,001
precip_total_semana $\leftrightarrow$ duracion_total	0,383	< 0,001
viento_medio_semana $\leftrightarrow$ n_eventos	0,135	< 0,001

n_eventos se atenúa ($\rho = 0,29$), lo que indica que parte de la señal climática se concentra en la transición entre semanas sin y con interrupción, y no solo en la intensidad condicional de los eventos. La Figura 5.40 resume las correlaciones en este subconjunto.

**Figura 5.40:** Correlaciones de Spearman en semanas-cuadrante con $n_{\text{eventos}} > 0$ ($n = 13,351$).

En síntesis, el análisis de correlación sobre D_{mod} confirma: (i) **alta redundancia** entre variables operativas de severidad y entre temperaturas/vientos del bloque climático; (ii) **señal climática dominante** de la precipitación hacia la frecuencia e impacto de interrupciones; y (iii) **asociaciones débiles** de temperatura y

humedad en el grano semanal. Estos hallazgos fundamentan la selección de `precip_total_semana` (y eventualmente viento) como predictoras, la exclusión de variables climáticas redundantes y la definición explícita de la variable respuesta (`n_eventos` vs. `duracion_total` vs. indicadores de afectación) en la Etapa 4. El análisis multivariado formal (VIF, redundancia simultánea) se desarrolla en la Sección 5.3.8.

5.3.8. Evaluación inicial de relaciones multivariadas

Con fundamento en las redundancias bivariadas identificadas en la Sección 5.3.7, se evaluaron las relaciones **simultáneas** entre covariables sobre D_{mod} mediante VIF, PCA exploratorio, agrupamiento jerárquico de variables climáticas, correlación parcial y un GLM Poisson de diagnóstico. El procedimiento reproducible se documenta en [análisis_multivariado.html](#).

Multicolinealidad climática (VIF). Se estimó un modelo auxiliar lineal `n_eventos ~ bloque climático completo` para calcular el factor de inflación de la varianza (VIF) de cada covariable. La Figura 5.41 muestra VIF elevados en `temp_media_semana` (42,99), `viento_medio_semana` (19,63), `viento_max_semana` (17,87), `temp_max_semana` (17,17) y `temp_min_semana` (13,92), mientras `precip_total_semana` (1,05) y `humedad_media_semana` (4,56) presentan inflación baja. Al restringir el bloque a `precip_total_semana`, `temp_media_semana`, `humedad_media_semana` y `viento_medio_semana`, los VIF descienden a valores aceptables (máximo 6,94 en temperatura media; Tabla 5.27).





Figura 5.41: VIF del bloque climático en modelo auxiliar `n_eventos ~ clima ( $D_{\text{mod}}$ )`.

Tabla 5.27: VIF con subconjunto climático reducido propuesto para la Etapa 4

Variable	VIF
temp_media_semana	6,94
humedad_media_semana	3,44
viento_medio_semana	3,33
precip_total_semana	1,04

PCA exploratorio del bloque climático. El análisis de componentes principales (Figuras 5.42 y 5.43) condensa el 81,3 % de la varianza en las dos primeras componentes: PC1 explica el 66,5 % (eje temperatura–humedad–viento) y PC2 el 14,8 %. La precipitación aporta carga relativamente independiente en PC2–PC3, coherente con su bajo VIF y su rol como predictor no redundante.

**Figura 5.42:** Varianza explicada por componentes principales del bloque climático.

Agrupamiento jerárquico. El dendrograma de la Figura 5.44 confirma dos clusters principales: (i) temperaturas y vientos, altamente intercorrelados; y (ii) precip_total_semana, relativamente aislada. Este resultado valida la exclusión de temp_max_semana, temp_min_semana y viento_max_semana del conjunto predictor reducido.

Asociación multivariada clima → n_eventos. La correlación parcial de Spearman entre precipitación y n_eventos, controlando temp_media_semana y viento_medio_semana, es $\rho = 0,43$ (frente a $\rho = 0,41$ bivariado), lo que indica que la señal de lluvia persiste al aislar temperatura y viento. Un GLM Poisson exploratorio con subconjunto reducido (Figura 5.45) confirma coeficientes positivos y significativos para




Figura 5.43: Loadings de las tres primeras componentes principales del bloque climático.




Figura 5.44: Dendrograma de variables climáticas (distancia = $1 - |\rho_{\text{Spearman}}|$).

$\log(1+\text{precip})$ ($\hat{\beta} = 0,55$; $p < 0,001$) y viento medio estandarizado ($\hat{\beta} = 0,30$; $p < 0,001$), mientras temperatura y humedad aportan efectos marginales débiles en presencia conjunta de las demás covariables.




Figura 5.45: Coeficientes del GLM Poisson exploratorio $n_eventos \sim \text{clima reducido}$ (diagnóstico EDA).

Dimensiones del bloque operativo. El PCA sobre $\log(1+x)$ del bloque operativo (Figura 5.46) concentra el 83,8 % de la varianza en PC1, con cargas elevadas y del mismo signo en $n_eventos$, $usuarios_afectados$, $elementos_afectados$ y $duracion_total$. PC2 (11,9 %) contrasta frecuencia /afectación frente a duración. Ello respalda definir una métrica de respuesta principal por objetivo: $n_eventos$ como proxy de *SAIFI* (frecuencia) y $duracion_total$ como proxy de *SAIDI* (continuidad), sin emplear simultáneamente las cuatro variables operativas como respuestas o predictoras.

En síntesis, la evaluación multivariada sobre D_{mod} recomienda: (i) predictoras climáticas $precip_total_semana$, $temp_media_semana$, $humedad_media_semana$ y $viento_medio_semana$; (ii) $n_eventos$ como variable respuesta de frecuencia para el modelado de *SAIFI*; y (iii) exclusión de temperaturas extremas y viento máximo por redundancia simultánea. Estos criterios se operacionalizan en la depuración cuantitativa y la construcción de matrices de diseño de la Etapa 4.

5.3.9. Segmentación exploratoria

Con fundamento en la segmentación territorial introducida en la Sección 5.3.6, se profundizó la heterogeneidad de D_{mod} mediante perfiles comparativos por nivel de actividad, evolución 2024–2025, estratificación por régimen de preci-




Figura 5.46: Loadings PCA del bloque operativo en escala $\log(1+x)$.

pitación semanal y clustering multivariado de cuadrantes. El procedimiento reproducible se documenta en [segmentacion_exploratoria.html](https://segmentacion-exploratoria.html).

Perfiles por nivel de actividad. Sobre los 344 cuadrantes del periodo, la clasificación Baja/Media/Alta (cuantiles P50 y P85 entre cuadrantes con eventos) arroja: 162 cuadrantes baja (47,1 %), 113 media (32,8 %) y 49 alta (14,2 %); 20 cuadrantes (5,8 %) no registraron eventos. Los perfiles acumulados (Tabla implícita en Figura 5.48) muestran escalamiento marcado: media de 22 eventos por cuadrante en nivel baja frente a 114,6 en media y 344,7 en alta; usuarios afectados medios de 1,587 a 88,534 y precipitación media acumulada de 1,005 mm a 6,907 mm. La Figura 5.47 confirma que la dispersión semanal de *n_eventos* crece con el estrato territorial.

Evolución 2024 vs 2025 por estrato. El total territorial ascendió de 15,211 eventos en 2024 (287/semana) a 18,199 en 2025 (350/semana). Al desagregar por nivel fijado en el periodo completo, el ratio medio 2025/2024 es homogéneo: 1,24 (baja), 1,26 (media) y 1,24 (alta), lo que indica incremento transversal sin reordenamiento fuerte de la jerarquía territorial (Figura 5.49). El crecimiento observado en 2024–2025 debe interpretarse en coherencia con la homogeneización de codificación activo/sitio bajo OMS-SP7 (Sección 5.3.5), no exclusivamente como deterioro operativo.

Régimen climático semanal. Semanas con precipitación en o por encima del percentil 75 (25 % de las filas; 9,030 observaciones) presentan media de *n_eventos* de 2,01, frente a 0,56 en semanas secas (75 %; 27,090 filas), con 61,8 % vs. 28,7 % de semanas con al menos un evento. La prueba de Wilcoxon confirma diferencia




Figura 5.47: Distribución semanal de n_eventos por nivel de actividad del cuadrante (D_{mod}).




Figura 5.48: Perfil normalizado por nivel de actividad (eventos, usuarios, duración, semanas activas, clima).




Figura 5.49: Eventos acumulados por nivel de actividad y año en D_{mod} .

significativa ($p < 0,001$; Figura 5.50), coherente con la señal de precipitación de las Secciones 5.3.7 y 5.3.8.




Figura 5.50: n_eventos según régimen de precipitación semanal (umbral P75).

Clustering multivariado de cuadrantes. Se aplicó k-means ($k = 4$) sobre cuadrantes con al menos un evento, con variables estandarizadas de frecuencia, severidad, duración, clima y altitud (excluyendo covariables de varianza nula). El mapa de la Figura 5.51 y el heatmap de la Figura 5.52 distinguen: C1 (1 cuadrante; 2,224 eventos; hub extremo), C2 (41 cuadrantes; media 294 eventos; alta severidad y precipitación), C3 (169 cuadrantes; media 67 eventos; perfil intermedio-bajo) y C4 (113 cuadrantes; media 69 eventos; mayor altitud media,

1,797 m). La concentración en C1–C2 respalda evaluar modelado global frente a estratificación por cluster en la Etapa 4.




Figura 5.51: Clustering k-means de cuadrantes ($k = 4$) en D_{mod} .




Figura 5.52: Perfil medio por cluster de cuadrantes (variables operativas y climáticas).

En síntesis, la segmentación exploratoria sobre D_{mod} evidencia: (i) heterogeneidad territorial persistente (14,2 % de cuadrantes en nivel alta concentran actividad desproporcionada); (ii) incremento homogéneo 2024→2025 en todos los

estratos; (iii) mayor frecuencia de interrupciones en semanas lluviosas; y (iv) cuatro perfiles espaciales distinguibles por clustering. Estos criterios orientan la estratificación territorial y la partición entrenamiento/prueba de la Etapa 4.

5.3.10. Resultados y entregables de la etapa

La Etapa 3 sobre D_{mod} (2024–2025; 36,120 filas cuadrante $\times$ semana) produjo un diagnóstico exploratorio integrado: calidad y distribución de variables (Secciones 5.3.1–5.3.4), delimitación temporal y materialización del panel de modelado (Sección 5.3.5), patrones y visualización (Sección 5.3.6), correlación bivariada (Sección 5.3.7), evaluación multivariada con recomendación de predictoras y respuesta (Sección 5.3.8) y segmentación territorial (Sección 5.3.9). Los hallazgos convergentes son: (i) **precipitación semanal** como señal climática dominante hacia n_{eventos} ; (ii) **redundancia** en bloques operativo y climático que justifica subconjuntos reducidos; (iii) **n_{eventos}** como proxy de frecuencia (*SAIFI*) y duracion_total como proxy de continuidad (*SAIDI*); (iv) **heterogeneidad espacial** y clusters territoriales que sugieren estratificación en el modelado; y (v) **partición natural** entrenamiento 2024 / prueba 2025 bajo cobertura homogénea de emparejamiento evento–elemento. Los informes HTML reproducibles enlazados en el índice del repositorio constituyen el soporte técnico de esta etapa; el **entregable ejecutivo consolidado** se documenta en [EDA.html](#) (síntesis de las Secciones 5.3.1–5.3.10 con hallazgos, figuras representativas y lineamientos para la Etapa 4). Las decisiones de ingeniería de variables se operacionalizan en dicha etapa siguiente.

Resultado: conocimiento exploratorio del comportamiento de los datos y hallazgos relevantes para el modelado.

Entregable: Documento de análisis descriptivo y exploratorio (EDA)—[EDA.html](#).

5.4. Etapa 4 – Ingeniería de variables y preparación del modelo

Objetivo específico asociado: OE2

Objetivo: construir las variables analíticas necesarias para el entrenamiento de modelos predictivos, asegurando un dataset consistente, balanceado y estadísticamente apto para la modelación.

A partir de los hallazgos del EDA, en esta etapa se transforma el dataset consolidado en una representación analítica adecuada para el entrenamiento de modelos. Esto incluye la definición formal de la variable respuesta, la construcción de variables predictoras informadas por el comportamiento observado, la depuración y codificación de covariables, la estandarización de variables conti-

nuas y la definición de las particiones temporales de entrenamiento y prueba. El preprocesamiento orientado al modelado —incluida la selección de variables con base en los análisis de asociación del EDA— se concentra en esta etapa, en coherencia con criterios de estabilidad numérica, identificabilidad del modelo y validez de supuestos.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.4.1. Construcción de variables predictoras

5.4.2. Construcción de la variable respuesta

5.4.3. Análisis de asociación y depuración de variables cuantitativas

5.4.4. Análisis de asociación y depuración de variables cualitativas

5.4.5. Codificación de variables categóricas

5.4.6. Estandarización de variables cuantitativas

5.4.7. Generación de ventanas temporales

5.4.8. Partición de datos en entrenamiento y prueba

Con fundamento en el diagnóstico de cobertura del emparejamiento evento–elemento (Sección 5.3.5), el universo de estimación se restringe a D_{mod} : observaciones cuadrante $\times$ semana con $\text{year}(\text{semana}) \in \{2024, 2025\}$, periodo en el que la coincidencia entre COMPONENTE_FALLADO y el inventario GIS (`tipo_elemento.csv`) alcanza al menos el 79,8 %, frente a ≈ 31 % en 2021–2023 bajo OMS-SPARD. La partición temporal propuesta asigna las observaciones de **2024** al conjunto de entrenamiento y las de **2025** al conjunto de prueba, preservando el orden cronológico y la validez de la validación en series autocorrelacionadas (ACF reza-
go 1 = 0,92 en D_{EDA}). Los años 2021–2023 no se incluyen en el entrenamiento ni en la prueba del modelo predictivo, dado el sesgo por incompatibilidad entre código de activo y código de sitio.

5.4.9. Construcción de matrices de diseño

5.4.10. Reducción de dimensionalidad

5.4.11. Segmentación analítica

5.4.12. Transformaciones adicionales para modelado

5.4.13. Resultados y entregables de la etapa

Resultado: dataset analítico listo para entrenamiento y validación del modelo.

Entregable: Reporte técnico de ingeniería de variables y dataset analítico documentado.

5.5. Etapa 5 – Modelado predictivo y evaluativo

Objetivo específico asociado: OE2 y OE3

Objetivo: entrenar, validar y evaluar modelos predictivos utilizando métricas de desempeño que permitan estimar *SAIDI* y *SAIFI* por circuito o área.

En esta etapa se desarrollan y evalúan diversos modelos estadísticos y de aprendizaje automático. La selección del enfoque (supervisado, no supervisado o híbrido) se determina según los hallazgos del análisis exploratorio, la naturaleza de los datos disponibles y los requerimientos de interpretabilidad. La evaluación comparativa considera métricas de error como *RMSE*, *MAE* y *MAPE*, así como la estabilidad del modelo y la validez de supuestos. Adicionalmente, se realiza un análisis de importancia de variables mediante técnicas interpretables, con el objetivo de identificar los factores operativos, técnicos o climáticos que influyen de manera significativa en la calidad del servicio.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.5.1. Selección de algoritmos

5.5.2. Entrenamiento del modelo

5.5.3. Validación del modelo

5.5.4. Ajuste de hiperparámetros

5.5.5. Evaluación de desempeño

5.5.6. Comparación de modelos

5.5.7. Interpretación de resultados

5.5.8. Resultados y entregables de la etapa

Resultado: modelo predictivo validado y evaluado técnicamente.

Entregables: Informe de evaluación comparativa de modelos predictivos (OE3) y reporte técnico de importancia de variables (OE2).

5.6. Etapa 6 – Cierre metodológico, documentación y reportes

Objetivo específico asociado: OE1–OE2–OE3

Objetivo: presentar los resultados obtenidos y documentar el proceso metodológico desarrollado, asegurando la reproducibilidad y la trazabilidad de los hallazgos.

En la etapa final se consolidan los resultados del proyecto y se documentan de forma integral las técnicas aplicadas, las transformaciones realizadas y el código reproducible (en R o Python). El capítulo incluye apéndices técnicos, tablas de validación, bibliografía y lineamientos de reproducibilidad, así como una discusión orientada a interpretar los hallazgos en términos técnicos y operativos para la toma de decisiones del operador de red.

Las actividades desarrolladas en esta etapa se describen en las subsecciones siguientes.

5.6.1. Presentación de resultados del modelo

5.6.2. Métricas de desempeño

5.6.3. Hallazgos principales

5.6.4. Interpretación técnica y operativa

5.6.5. Generación de reportes

5.6.6. Discusión de resultados

5.6.7. Limitaciones y trabajos futuros

5.6.8. Resultados y entregables de la etapa

Resultado: documentación final del proyecto y resultados consolidados.

Entregables: Compendio de documentación del proyecto (informe final, informe descriptivo, informe de evaluación de modelos y reporte técnico de variables relevantes), código reproducible y documentación detallada de procesos y transformaciones.

Resultados

6.1. Resultados de la estimación del modelo

7

Discusión y trabajo futuro

7.1. Discusión

7.2. Trabajos futuros

Conclusiones

- 8.1. Conclusión asociada al objetivo general
- 8.2. Conclusión asociada al objetivo específico 1
- 8.3. Conclusión asociada al objetivo específico 2
- 8.4. Conclusión asociada al objetivo específico 3

Bibliografía

- [1] Comisión de Regulación de Energía y Gas (CREG), «Resolución CREG 015 de 2018 – Por la cual se establecen los indicadores de calidad del servicio de energía eléctrica y las fórmulas de compensación,» CREG, Bogotá, Colombia, inf. téc., 2018. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0015_2018.htm
- [2] S.-S. de Servicios Públicos Domiciliarios, «Resolución SSPD 20192200020155,» Superintendencia de Servicios Públicos Domiciliarios, inf. téc., 2019, [Online; accessed 2025-11-23]. dirección: <https://www.superservicios.gov.co/node/5072>
- [3] IEEE Power and Energy Society, «IEEE Std 1366-2012: IEEE Guide for Electric Power Distribution Reliability Indices,» IEEE, New York, USA, inf. téc., 2012.
- [4] IDEAM, «Boletín climático nacional,» Instituto de Hidrología, Meteorología y Estudios Ambientales, Bogotá, Colombia, inf. téc., 2023.
- [5] J. M. A. Ospina y T. L. López, «Efecto de variables meteorológicas en la confiabilidad del servicio eléctrico en Colombia,» *Revista Energética Colombiana*, vol. 18, n.º 2, págs. 67-75, 2020.
- [6] D. M. Pérez y L. J. Echeverría, «Aplicación de herramientas de analítica de datos para la mejora de indicadores de calidad eléctrica en redes de distribución,» *Ingeniería y Desarrollo*, vol. 39, n.º 1, págs. 25-40, 2021.
- [7] Y. L. Huang y Z. M. Zhang, «Application of deep learning to predict SAIDI and SAIFI indicators in smart grids,» *IEEE Transactions on Smart Grid*, vol. 11, n.º 6, págs. 5153-5163, 2020.
- [8] República de Colombia, *Decreto Único Reglamentario del Sector Presidencia de la República 1081 de 2015; Decreto 103 de 2015; Ley 1712 de 2014 – Transparencia y Acceso a Información Pública; Resolución 1519 de 2020 – Gobierno Digital*, Marco normativo sobre transparencia y acceso a la información pública en Colombia, 2015.

-
- [9] Superintendencia de Servicios Públicos Domiciliarios (SSPD), «Circular 063 de 2019 – Criterios técnicos para el cálculo de indicadores de calidad del servicio de energía eléctrica,» Superintendencia de Servicios Públicos Domiciliarios, Bogotá, Colombia, Circular 063, 2019, [En línea]. dirección: [https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/3f419691a2b6e75c0525845600497ea7/\\$FILE/Circular063-2019.pdf](https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/3f419691a2b6e75c0525845600497ea7/$FILE/Circular063-2019.pdf)
 - [10] Y. Wang y S. Chen, «Modern reliability assessment of power distribution systems: A data-driven approach,» *Energies*, vol. 12, n.º 15, pág. 2857, 2019.
 - [11] K. Xie, H. Zhang y C. Singh, «Reliability forecasting models for electrical distribution systems considering component failures and planned outages,» *International Journal of Electrical Power & Energy Systems*, vol. 78, págs. 337-346, 2016. doi: [10.1016/j.ijepes.2016.01.020](https://doi.org/10.1016/j.ijepes.2016.01.020)
 - [12] S. Das, P. Kankanala y A. Pahwa, «Outage Estimation in Electric Power Distribution Systems Using a Neural Network Ensemble,» *Energies*, 2021. doi: [10.3390/en14164797](https://doi.org/10.3390/en14164797)
 - [13] M. Angalakudati et al., «Improving emergency storm planning using machine learning,» en *2014 IEEE PES T&D Conference and Exposition*, 2014. doi: [10.1109/TDC.2014.6863406](https://doi.org/10.1109/TDC.2014.6863406)
 - [14] D. Owerko, F. Gama y A. Ribeiro, «Predicting Power Outages Using Graph Neural Networks,» en *IEEE Global Conference on Signal and Information Processing*, 2018. doi: [10.1109/GLOBALSIP.2018.8646486](https://doi.org/10.1109/GLOBALSIP.2018.8646486)
 - [15] D. Cerrai, P. L. Watson y E. N. Anagnostou, «Assessing the effects of a vegetation management standard on distribution grid outage rates,» *Electric Power Systems Research*, 2019. doi: [10.1016/j.epsr.2019.105909](https://doi.org/10.1016/j.epsr.2019.105909)
 - [16] R. Eskandarpour y A. Khodaei, «Machine Learning Based Power Grid Outage Prediction in Response to Extreme Events,» *IEEE Transactions on Power Systems*, 2017. doi: [10.1109/TPWRS.2016.2631895](https://doi.org/10.1109/TPWRS.2016.2631895)
 - [17] C. Rudin et al., «Machine Learning for the New York City Power Grid,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2012. doi: [10.1109/TPAMI.2011.108](https://doi.org/10.1109/TPAMI.2011.108)
 - [18] L. Xu, M.-Y. Chow, J. Timmis y L. Taylor, «Power Distribution Outage Cause Identification With Imbalanced Data Using Artificial Immune Recognition System (AIRS) Algorithm,» *IEEE Transactions on Power Systems*, 2007. doi: [10.1109/TPWRS.2006.889040](https://doi.org/10.1109/TPWRS.2006.889040)
 - [19] L. Breiman, «Random Forests,» *Machine Learning*, 2003. doi: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324)

- [20] S.-R. Han, S. D. Guikema, S. M. Quiring, K. H. Lee, D. V. Rosowsky y R. A. Davidson, «Estimating the spatial distribution of power outages during hurricanes in the Gulf coast region,» *Reliability Engineering & System Safety*, 2009. doi: [10.1016/j.ress.2008.02.018](https://doi.org/10.1016/j.ress.2008.02.018)
- [21] F. Yang, D. W. Wanik, D. Cerrai, M. A. E. Bhuiyan y E. N. Anagnostou, «Quantifying Uncertainty in Machine Learning-Based Power Outage Prediction Model Training: A Tool for Sustainable Storm Restoration,» *Sustainability*, 2020. doi: [10.3390/su12041525](https://doi.org/10.3390/su12041525)
- [22] P. Kankanala, S. Das y A. Pahwa, «AdaBoost+: An Ensemble Learning Approach for Estimating Weather-Related Outages in Distribution Systems,» *IEEE Transactions on Power Systems*, 2013. doi: [10.1109/TPWRS.2013.2281137](https://doi.org/10.1109/TPWRS.2013.2281137)
- [23] Y. Kor, M. Reformat y P. Musilek, «Predicting Weather-related Power Outages in Distribution Grid,» en *IEEE Power & Energy Society General Meeting*, 2020. doi: [10.1109/PESGM41954.2020.9281829](https://doi.org/10.1109/PESGM41954.2020.9281829)
- [24] M. Doostan y B. Chowdhury, «Predicting Lightning-Related Outages in Power Distribution Systems: A Statistical Approach,» *IEEE Access*, 2020. doi: [10.1109/ACCESS.2020.2991923](https://doi.org/10.1109/ACCESS.2020.2991923)
- [25] P.-C. Chen y M. Kezunović, «Fuzzy logic approach to predictive risk analysis in distribution outage management,» en *IEEE Power & Energy Society General Meeting*, 2017. doi: [10.1109/PESGM.2017.8274298](https://doi.org/10.1109/PESGM.2017.8274298)
- [26] J. He, D. W. Wanik, B. Hartman, E. N. Anagnostou, M. Astitha y M. Freidani, «Nonparametric Tree-Based Predictive Modeling of Storm Outages on an Electric Distribution Network,» *Risk Analysis*, 2017. doi: [10.1111/risa.12652](https://doi.org/10.1111/risa.12652)
- [27] H. Hou et al., «Spatial distribution assessment of power outage under typhoon disasters,» *International Journal of Electrical Power & Energy Systems*, 2021. doi: [10.1016/j.ijepes.2021.107169](https://doi.org/10.1016/j.ijepes.2021.107169)
- [28] M. Li et al., «Prediction of Power Outage Quantity of Distribution Network Users under Typhoon Disaster Based on Random Forest and Important Variables,» 2021. doi: [10.1155/2021/6682242](https://doi.org/10.1155/2021/6682242)
- [29] C. Zhai, T. Y.-J. Chen, A. White y S. D. Guikema, «Power outage prediction for natural hazards using synthetic power distribution systems,» *Reliability Engineering & System Safety*, 2021. doi: [10.1016/j.ress.2020.107348](https://doi.org/10.1016/j.ress.2020.107348)
- [30] D. Zhu, D. Cheng, R. Broadwater y C. Scirbona, «Storm modeling for prediction of power distribution system outages,» *Electric Power Systems Research*, 2007. doi: [10.1016/j.epsr.2006.08.020](https://doi.org/10.1016/j.epsr.2006.08.020)

-
- [31] A. Arif y Z. Wang, «Distribution Network Outage Data Analysis and Repair Time Prediction Using Deep Learning,» en *IEEE International Conference on Probabilistic Methods Applied to Power Systems*, 2018. DOI: [10.1109/PMAPS.2018.8440354](https://doi.org/10.1109/PMAPS.2018.8440354)
 - [32] D. W. Wanik, E. N. Anagnostou, B. Hartman, M. Frediani y M. Astitha, «Storm outage modeling for an electric distribution network in Northeastern USA,» *Natural Hazards*, 2015. DOI: [10.1007/s11069-015-1908-2](https://doi.org/10.1007/s11069-015-1908-2)
 - [33] A. Jaech, B. Zhang, M. Ostendorf y D. S. Kirschen, «Real-Time Prediction of the Duration of Distribution System Outages,» *IEEE Transactions on Power Systems*, 2018. DOI: [10.1109/TPWRS.2018.2860904](https://doi.org/10.1109/TPWRS.2018.2860904)
 - [34] D. Sorokin, «Machine learning application for power systems reliability assessment,» en *E3S Web of Conferences*, vol. 461, 2023. DOI: [10.1051/e3sconf/202346101032](https://doi.org/10.1051/e3sconf/202346101032)
 - [35] Z. Liu, J. Li, T. Zhang y J. Shao, «Rapid Calculation of Active Distribution Network Reliability Based on Dynamic Equipment Failure Rate,» *Energies*, vol. 16, n.º 14, 2023. DOI: [10.3390/en16145245](https://doi.org/10.3390/en16145245)
 - [36] E. Avcı, «Hybrid Artificial Intelligence Techniques for Enhanced Electricity Outage Prediction and Management in Distribution Networks,» *Turkish Journal of Electrical Power and Energy Systems*, 2024. DOI: [10.5152/TEPES.2024.24008](https://doi.org/10.5152/TEPES.2024.24008)
 - [37] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política de Gestión de Tecnologías de la Información*, Sesión Junta Directiva No. 800, feb. de 2018.
 - [38] Unidad de Planeación Minero Energética (UPME), «Plan de expansión de referencia generación - transmisión 2017 - 2031,» Ministerio de Minas y Energía, Bogotá, Colombia, inf. téc., 2017.
 - [39] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Política Sistema de Gestión Integrado*, Sesión Junta Directiva No. 831, abr. de 2020.
 - [40] CENS – Centrales Eléctricas de Norte de Santander S.A. E.S.P., *Instrumentos de gestión de información pública*, <https://www.cens.com.co/transparencia-y-acceso-a-la-informacion-publica/instrumentos-de-gestion-de-informacion-publica>, En línea; consultado, 2024.
 - [41] IDEAM, *E-SGI-PI003 Política Institucional de Gestión de Información Estadística*, <http://www.meteoaeronautica.gov.co/documents/24189/126529520/E-SGI-PI003+-Pol%C3%ADtica+Gesti%C3%B3n+de+Informaci%C3%B3n+Estadistica.pdf>, En línea, 2023.

- [42] IDEAM, *Transparencia y acceso a la información pública*, <https://www.ideam.gov.co/transparencia>, En línea, 2024.

A

Appendix

A.1. Parte 1

A.2. Parte 2